

GUIA PRÁTICO

Claude Code com Modelo Gratuito

Como conectar o Claude Code a modelos locais do Ollama, rodando totalmente offline e sem custo por token, usando a API compatível com Anthropic oferecida pelo Ollama.

Material de apoio · Claude Code (Gratuito) com Ollama
Claude Code com Modelo Gratuito

1. Como funciona a integração

O Claude Code normalmente se conecta à API da Anthropic para executar os modelos Claude. A partir da versão 0.14, o Ollama passou a oferecer uma API compatível com o formato Anthropic Messages, o que permite que o Claude Code converse diretamente com modelos rodando localmente pelo Ollama — sem proxies intermediários e sem custo por token.

Pré-requisitos

Ollama instalado e em execução (veja o guia [Instalando e Configurando Ollama](#)) e o Claude Code instalado. Se o Claude Code ainda não estiver instalado, o próprio fluxo abaixo cuida disso.

2. Início rápido: ollama launch claude

A forma mais simples de começar é usando o comando integrado do Ollama, que instala o Claude Code se necessário, seleciona um modelo local e já inicia a sessão conectada:

```
ollama launch claude
```

O comando abre um seletor interativo para escolher o modelo (local ou na nuvem) e, em seguida, inicia o Claude Code já configurado para conversar com esse modelo.

Rodando sem interação (scripts, Docker, CI)

Use a flag `--yes` para pular os seletores. Nesse modo, o parâmetro `--model` é obrigatório e o Ollama baixa o modelo automaticamente se ele ainda não existir localmente:

```
ollama launch claude --model gemma4:cloud --yes -- -p "como este repositório funciona?"
```

Tudo que vier depois de `--` é passado diretamente para o Claude Code.

3. Configuração manual (passo a passo)

Para quem prefere configurar manualmente, ou já tem o Claude Code instalado, basta apontar as variáveis de ambiente da Anthropic para o servidor local do Ollama.

- 1 Instale o Claude Code (caso ainda não tenha):

```
curl -fsSL https://claude.ai/install.sh | bash
```

- 2 Defina as variáveis de ambiente apontando para o Ollama local:

```
export ANTHROPIC_AUTH_TOKEN=ollama
export ANTHROPIC_API_KEY=""
export ANTHROPIC_BASE_URL=http://localhost:11434
```

- 3 Execute o Claude Code informando o modelo local desejado:

```
claude --model qwen3.5
```

Tudo em uma linha só

Também é possível definir as variáveis inline, sem exportá-las permanentemente na sessão do terminal:

```
ANTHROPIC_AUTH_TOKEN=ollama ANTHROPIC_BASE_URL=http://localhost:11434 ANTHROPIC_API_KEY="" claude
```

Configurações do Claude Code podem sobrescrever as variáveis

Se o Claude Code já tiver uma URL base ou credenciais salvas nas suas configurações locais, elas têm prioridade sobre as variáveis de ambiente do shell. Atualize essas configurações também, se necessário.

4. Escolhendo o modelo certo

Escolha um modelo com contexto suficiente para o tamanho do seu repositório. Para projetos maiores, configure um contexto de 64k tokens ou mais.

TIPO	CARACTERÍSTICAS	QUANDO USAR
Modelos locais	Rodam 100% na sua máquina, sem custo por token, funcionam offline	Privacidade total e uso sem limite de requisições
Modelos na nuvem (Ollama Cloud)	Modelos maiores, sem precisar baixar nem ter hardware potente	Tarefas que exigem mais capacidade do que a máquina local suporta

Ajustando o tamanho do contexto

Consulte a documentação de context length do Ollama para aumentar a janela de contexto do modelo local escolhido antes de trabalhar em repositórios grandes.

5. Usando Ollama Cloud diretamente (alternativa)

Também é possível conectar o Claude Code direto à nuvem do Ollama, sem precisar instalar o Ollama localmente — útil em máquinas sem capacidade para rodar modelos, mas nesse caso o uso está sujeito às cotas gratuitas/pagas da sua conta Ollama.

- 1
- Gere uma chave de API na sua conta Ollama e exporte-a:

```
export OLLAMA_API_KEY="sua-chave-aqui"
```

- 2
- Rode o Claude Code apontando para a nuvem do Ollama:

```
ANTHROPIC_BASE_URL=https://ollama.com \  
ANTHROPIC_AUTH_TOKEN="$OLLAMA_API_KEY" \  
ANTHROPIC_API_KEY="" \  
claude --model glm-5.3-flash
```

6. Recursos que continuam funcionando

Com o Claude Code conectado a um modelo do Ollama, os principais recursos do Claude Code continuam disponíveis (dependendo do suporte do modelo escolhido):

RECURSO	DESCRIÇÃO
Chat	Perguntas sobre o repositório ou a tarefa atual
Linha de comando	Execução de comandos com o fluxo de permissões do Claude Code
Uso de ferramentas	Tool calling, com modelos compatíveis
Edição de arquivos	Leitura e edição de arquivos do projeto
Subagentes	Divisão de trabalho em tarefas paralelas
Busca e leitura na web	Via API de busca do próprio Ollama
Visão	Envio de imagens e capturas de tela, com modelos compatíveis
Thinking	Controles de raciocínio, com modelos compatíveis

Tarefas agendadas com /loop

Dentro do Claude Code, é possível rodar um prompt ou comando em intervalos regulares:

```
/loop 30m Verifique meus PRs abertos e resuma o status
/loop 1h Pesquise as últimas notícias de IA e resuma os principais pontos
/loop 15m Verifique novas issues no GitHub e priorize-as
```

7. Solução de problemas comuns

Claude Code não conecta ao modelo local

Verifique se o Ollama está em execução (`sudo systemctl status ollama` ou `ollama serve`) e se `ANTHROPIC_BASE_URL` aponta corretamente para `http://localhost:11434`.

Respostas cortadas ou perda de contexto em repositórios grandes

Aumente a janela de contexto do modelo para 64k tokens ou mais antes de iniciar a sessão.

Configuração salva sobrescrevendo as variáveis de ambiente

Revise as configurações locais do Claude Code (URL base e credenciais salvas), pois elas têm prioridade sobre variáveis exportadas no terminal.