

RESUMO DA SEÇÃO

Claude Code (Gratuito) com Ollama

Panorama de tudo o que foi abordado nesta seção: da instalação do Ollama até rodar o Claude Code sem custo, usando modelos locais.

1. Visão geral

Esta seção mostra como usar o Claude Code sem pagar por tokens de API, conectando-o a modelos de linguagem rodando localmente através do Ollama. Ao final, o Claude Code funciona 100% no seu computador, com privacidade total e sem depender da nuvem. A seção está organizada em quatro materiais, na seguinte ordem sugerida de estudo:

01

Conhecendo a Ferramenta Ollama

Ollama_ClaudeCode_Local.pptx

Apresentação introdutória: o que é o Ollama, por que combiná-lo com o Claude Code, modelos leves recomendados por faixa de RAM, e uma comparação direta entre Claude API e Ollama Local.

02

Instalando e Configurando Ollama

Instalando o Ollama no Linux.pdf

Passo a passo de instalação no Linux (script oficial e instalação manual), configuração como serviço systemd, primeiros testes e comandos essenciais do dia a dia.

03

Baixando Modelos no Ollama

Baixando Modelos no Ollama.pdf

Como encontrar modelos na biblioteca oficial, baixar variantes com ollama pull, escolher tamanho e quantização adequados, gerenciar modelos baixados e importar modelos GGUF do Hugging Face.

04

Claude Code com Modelo Gratuito

Claude Code com Modelo Gratuito.pdf

Como conectar o Claude Code diretamente a um modelo do Ollama via ollama launch claude ou configuração manual das variáveis de ambiente da Anthropic, incluindo a opção de usar o Ollama Cloud.

2. O que é o Ollama e por que usá-lo com o Claude Code

O Ollama é uma ferramenta open-source que baixa e executa modelos de linguagem (LLMs) diretamente no computador do usuário, sem depender de serviços em nuvem. Combinado ao Claude Code, ele permite usar o agente de codificação da Anthropic sem custo de API, com os dados do projeto nunca saindo da máquina.

VANTAGEM	DESCRIÇÃO
Gratuito	Sem cobrança por token; uso ilimitado no hardware local
Privacidade total	Código e dados nunca saem do computador
Funciona offline	Não depende de conexão com a internet

3. Instalando o Ollama (recapitulando)

- 1 Instalação rápida via script oficial:

```
curl -fsSL https://ollama.com/install.sh | sh
```

- 2 O serviço é registrado no systemd e gerenciado com:

```
sudo systemctl status ollama
sudo systemctl start ollama
```

Detalhes completos

Instalação manual (tarball), configuração de host/porta e solução de problemas estão no guia Instalando e Configurando Ollama.

4. Baixando modelos (recapitulando)

Modelos são identificados como nome:tag e baixados com ollama pull. Para máquinas com menos RAM, prefira variantes pequenas e quantizadas.

```
ollama pull qwen2.5:1.5b
```

MODELO	TAMANHO	RAM MÍN.	INDICADO PARA
qwen2.5:0.5b	~400 MB	1 GB	Ultra leve
qwen2.5:1.5b	~1 GB	2 GB	Chat geral
gemma3:1b	~800 MB	2 GB	Rápido e capaz
llama3.2:3b	~2 GB	4 GB	Confiável e geral
qwen2.5-coder:3b	~2 GB	4 GB	Código
phi4-mini	~2.5 GB	4 GB	Raciocínio

Dica

Para tarefas de programação, prefira modelos da família coder (ex.: qwen2.5-coder) — mesmo em versões menores, costumam superar modelos genéricos maiores em código.

5. Claude Code + Ollama (recapitulando)

Duas formas de conectar o Claude Code a um modelo local:

- 1
- Integrado (recomendado): instala e inicia tudo automaticamente.

```
ollama launch claude
```

- 2
- Manual: aponte as variáveis de ambiente da Anthropic para o Ollama local.

```
export ANTHROPIC_AUTH_TOKEN=ollama
export ANTHROPIC_API_KEY=""
export ANTHROPIC_BASE_URL=http://localhost:11434

claude --model qwen3.5
```

Configurando o modelo padrão

```
claude config set model qwen2.5:1.5b
ollama list
```

Use ollama list para conferir os modelos já disponíveis localmente antes de escolher o padrão.

6. Claude API vs. Ollama Local

CRITÉRIO	CLAUDE API (ANTHROPIC)	OLLAMA LOCAL
Custo	Pago por token	Gratuito
Privacidade	Dados na nuvem	100% local
Qualidade	Excelente	Boa (depende do modelo)
Velocidade	Depende da rede	Depende do hardware
Offline	Não	Sim
Configuração	Simples	Requer instalação

7. Comece agora: 3 comandos

- 1 Baixar um modelo leve:

```
ollama pull qwen2.5:1.5b
```

- 2 Configurar a URL do Claude Code:

```
export ANTHROPIC_BASE_URL="http://localhost:11434/v1"
```

- 3 Iniciar o Claude Code com o modelo escolhido:

```
claude --model qwen2.5:1.5b
```

Boas práticas para modelos locais

Crie um CLAUDE.md na raiz do projeto com contexto e convenções, mantenha as conversas curtas com /clear entre sessões distintas, e evite arquivos muito grandes na mesma conversa — modelos locais têm janelas de contexto mais limitadas que a API oficial.