

Analizador de Texto: *descartando stopwords*

Última etapa do analisador: tirar da contagem as **stopwords**, palavras como "o", "e", "de" que aparecem em qualquer texto e escondem o assunto. O agente cria uma lista em português num arquivo editável, um interruptor para ligar e desligar e um campo para você acrescentar palavras. A nuvem finalmente mostra do que o texto trata.

Stopwords

stopwords_pt.txt

Conjuntos (set)

st.sidebar · st.toggle

Antes e depois

NLTK como alternativa

Formação Claude Code 2026 · Baseado em amueller.github.io/word_cloud, nltk.org (stopwords corpus), docs.python.org (set) e docs.streamlit.io (st.sidebar, st.toggle), consultados em outubro de 2026 · Código de referência testado em [projeto/](#) · Telas: print real

O que são *stopwords*

Stopwords são palavras muito frequentes que quase não carregam significado sozinhas: artigos, preposições, conjunções, pronomes e verbos auxiliares.

o · a · os · as

de · do · da · em · no

e · ou · mas

que · se · com · para

ele · ela · seu

é · foi · ser · tem

No texto de exemplo, as stopwords somam **106 das 247** palavras: quase metade. Por isso dominavam a nuvem.

NÃO EXISTE LISTA OFICIAL

Cada biblioteca tem a sua, e cada projeto ajusta. "Não", por exemplo: num analisador de opiniões, "não gostei" muda tudo, então "não" **não** deve sair. O código de referência mantém "não" fora da lista.

Tirar stopwords serve para **descobrir o assunto** (nuvem, frequência). As métricas gerais (total de palavras, frases, tempo de leitura) continuam contando tudo.

O pedido *da versão 3*

Remova as stopwords da nuvem e da frequência:

- crie stopwords_pt.txt, uma palavra por linha, com linhas de comentário começando com #; inclua artigos, preposições, contrações (do, na, pelo), pronomes e verbos auxiliares comuns; NÃO inclua "não";
- em analise.py: carregar_stopwords() e sem_stopwords(lista, stopwords);
- na barra lateral: interruptor "Remover stopwords" (ligado) e um campo para palavras extras separadas por vírgula;
- mostre quantas ocorrências foram ignoradas. As métricas gerais continuam contando tudo.

DECISÃO	POR QUÊ
Lista num arquivo <code>.txt</code>	Qualquer pessoa edita sem mexer no código
"NÃO inclua não"	Uma decisão de produto, tomada por você
Interruptor	Dá para comparar o antes e o depois
Palavras extras	Cada texto tem as suas ("mostra", no exemplo)
"métricas contando tudo"	Evita mudar o que já estava certo

A lista *e as funções*

STOPWORDS_PT.TXT (COMEÇO; 105 PALAVRAS NO TOTAL)

```
# Stopwords em português: palavras muito comuns que não dizem do que o texto trata.  
# Uma por linha. Linhas com # são comentários. Edite à vontade.  
a  
à  
ao  
aos  
aquela  
aquelas  
aquele  
aqueles  
aquilo  
as  
...
```

ANALISE.PY

```
def carregar_stopwords(caminho=Path(__file__).with_name("stopwords_pt.txt")):  
    """Lê o arquivo de stopwords (uma por linha; # é comentário)."""  
    linhas = Path(caminho).read_text(encoding="utf-8").splitlines()  
    return {l.strip().lower() for l in linhas if l.strip() and not l.startswith("#")}  
  
def sem_stopwords(lista, stopwords):  
    return [p for p in lista if p not in stopwords]
```

- ✓ A lista vira um `set`: procurar num conjunto é instantâneo, mesmo com milhares de palavras
- ✓ `.lower()` e `.strip()` evitam erro por maiúscula ou espaço
- ✓ `sem_stopwords` é só um filtro: fácil de testar

A barra lateral *e o filtro*

```
with st.sidebar:
    st.header("Stopwords")
    remover = st.toggle("Remover stopwords", value=True)
    extras = st.text_input("Outras palavras para ignorar", placeholder="separadas por vírgula")
    stopwords = carregar_stopwords() | {p.strip().lower() for p in extras.split(",") if p.strip()}
    st.caption(f"{len(stopwords)} palavras na lista (arquivo stopwords_pt.txt + as suas).")

todas = palavras(texto)
if not todas:
    st.warning("O texto não tem palavras para analisar (só números ou símbolos).")
    st.stop()
lista = sem_stopwords(todas, stopwords) if remover else todas
dados = estatisticas(texto)
c1, c2, c3, c4, c5 = st.columns(5)
c1.metric("Palavras", dados["palavras"])
c2.metric("Únicas", dados["palavras_unicas"])
c3.metric("Frases", dados["frases"])
c4.metric("Caracteres", dados["caracteres"])
c5.metric("Leitura", f"{dados['minutos_leitura']} min")

if remover:
    st.caption(f"{len(todas) - len(lista)} ocorrências de stopwords ignoradas na nuvem e na frequência.")

if not lista:
    st.warning("Não sobrou nenhuma palavra depois de remover as stopwords.")
    st.stop()
```

- ✓ `|` une a lista do arquivo com as palavras extras
- ✓ `todas` e `lista`: a diferença é o que foi ignorado
- ✓ As métricas usam o texto inteiro; a nuvem e a frequência usam `lista`
- ✓ Texto sem letras, ou só com stopwords: um aviso e `st.stop()`, em vez de uma nuvem vazia (que daria erro na WordCloud)

O resto do `app.py` (abas, nuvem, download) é o da aula 17, recebendo a `lista` já filtrada.

A versão 3 *funcionando*



Print real do projeto/ com o exemplo.txt

Stopwords

☒ Remove stopwords

Outras palavras para ignorar

separadas por vírgula

105 palavras na lista (arquivo stopwords_pt.txt + as suas).

```
Barra lateral · print real
```

"mostra" ainda aparece grande. Ela é do assunto ou é ruído? No exemplo, é ruído: escreva "mostra" em **Outras palavras para ignorar**.

Lista própria *ou* *NLTK*?

	STOPWORDS_PT.TXT	NLTK
Instalação	Nenhuma	<code>pip install nltk</code> + baixar o corpus
Tamanho	105 palavras, escolhidas	Lista maior, pronta
Controle	Total: edite o arquivo	Ajuste por código (somar ou tirar palavras)
Internet	Não precisa	Precisa para baixar o corpus a primeira vez

COM NLTK

```
import nltk
nltk.download("stopwords") # uma vez
from nltk.corpus import stopwords
lista = set(stopwords.words("portuguese"))
```

Peça ao agente para **comparar** as duas listas no seu texto: *"que palavras a lista do NLTK remove e a nossa não, e vice-versa?"*. Decida olhando o resultado.

Roteiro *de teste*

TESTE	ESPERADO (NO EXEMPLO)
Abrir o app	"106 ocorrências de stopwords ignoradas"; nuvem com "agente" em destaque
Desligar o interruptor	Volta a nuvem da aula 17
Extras: "agente, mostra"	117 ignoradas; lista com 107 palavras
Texto "o e de um"	Aviso "Não sobrou nenhuma palavra..."
Texto "123 456"	Aviso "O texto não tem palavras..."
Métricas	Iguais com o interruptor ligado ou desligado
Editar o .txt e recarregar	A lista nova vale

Todos os valores da tabela são do teste automatizado do código de referência: 106 e 117 ignoradas, 105 e 107 palavras na lista e o aviso quando só há stopwords.

Crie testes para `carregar_stopwords` e `sem_stopwords`: comentários ignorados, maiúsculas, espaços sobrando e uma lista vazia.

O analisador *em três aulas*

VERSÃO	O QUE ENTROU	LIÇÃO
v1 · aula 16	Métricas, mais frequentes, tabela e gráfico	Definir o que é palavra; casos difíceis viram testes
v2 · aula 17	Nuvem de palavras, abas, download	Dependência nova autorizada; resultado certo ≠útil
v3 · aula 18	Stopwords em arquivo, interruptor, extras	Dados de configuração fora do código; decisões de produto ("não")

```
git add stopwords_pt.txt analyse.py app.py
git commit -m "Analisador de Texto: remove stopwords"
```

Para treinar: agrupar plurais ("agente" e "agentes"), contar pares de palavras, comparar dois textos lado a lado.

Teste o que *ficou*

1. O que são stopwords?

A) Palavras com erro de grafia

B) Palavras muito comuns que quase não dizem o assunto

C) Palavras em inglês

D) Palavras proibidas

B. Artigos, preposições, conjunções...

2. Por que a lista fica num arquivo .txt?

A) É mais rápido

B) Dá para editar sem mexer no código

C) O Streamlit exige

D) Para ir ao banco

B. Configuração fora do código.

3. Por que "não" ficou fora da lista?

A) Esquecimento

B) Ele muda o sentido ("não gostei")

C) Tem acento

D) É verbo

B. Decisão de produto.

4. As métricas gerais mudam ao remover stopwords?

A) Sim

B) Não: só a nuvem e a frequência usam a lista filtrada

C) Só o tempo de leitura

D) Só as frases

B. O texto continua do mesmo tamanho.

Menos palavras, *mais assunto*

As stopwords saíram da nuvem e da frequência: uma lista em `stopwords_pt.txt`, um `set` para filtrar, um interruptor e palavras extras na barra lateral. Agora "agente", "pedido" e "código" aparecem no lugar de "o", "e", "de". O analisador está completo.

`stopwords_pt.txt`

`set`

`st.toggle`

Antes e depois

NLTK

Próxima aula → 19 · Projeto Gerador Currículo · Primeira Versão

Fontes: amueller.github.io/word_cloud; nltk.org (Corpus readers, stopwords); docs.python.org (set, pathlib); docs.streamlit.io (st.sidebar, st.toggle, st.caption), consultados em outubro de 2026. Código de referência em `projeto/`, testado com wordcloud 1.9.6 e Streamlit 1.65; as nuvens da seção 05 foram geradas por ele.