

Por que o *Groq*?

Engenharia de prompt se aprende **testando**: escrever, rodar, comparar e ajustar, muitas vezes. Para isso, o módulo usa a API do **Groq**, uma nuvem de inferência rápida, com plano gratuito para começar e modelos de pesos abertos, como o `openai/gpt-oss-120b`, usado em todos os notebooks. Nesta aula: o que é o Groq, o que o torna rápido, os modelos, os limites de uso e como ele se encaixa no resto do módulo.

GroqCloud

LPU

`gpt-oss-120b`


Limites de uso

Compatível com OpenAI

Formação Claude Code 2026 · Baseado em console.groq.com/docs (Quickstart, Models, Rate Limits, OpenAI Compatibility, Reasoning) e groq.com, consultados em outubro de 2026 · Números de velocidade e limites mudam com o tempo: confira no console

Groq: uma nuvem feita *para rodar modelos*

- ✓ O Groq não cria os modelos: ele **hospeda** modelos de terceiros (OpenAI gpt-oss, Llama, Qwen, Whisper...) e os executa para você
- ✓ Você acessa pela **GroqCloud**: console em `console.groq.com`, chave de API e biblioteca Python `groq`
- ✓ Rodar um modelo já treinado para responder a pedidos se chama **inferência**, e é nisso que o Groq se especializou



Treino x inferência: treinar um modelo leva semanas em milhares de chips; a inferência acontece a cada pergunta e precisa ser rápida e barata.

O *LPU*: um chip só para inferência

- ✓ LPU (*Language Processing Unit*) é o processador que o Groq desenvolveu para executar modelos de linguagem
- ✓ A ideia central: guardar os dados em **memória SRAM dentro do próprio chip**, em vez de buscá-los numa memória separada a cada passo
- ✓ Resultado: muitos **tokens por segundo** e pouca espera, o que o Groq chama de baixa latência

GPT-05S-120B

~500

tokens/s

GPT-05S-20B

~1000

tokens/s

Velocidades informadas na página de modelos do Groq em outubro de 2026. Na prática, uma resposta de 500 tokens chega em cerca de 1 segundo.

Para quem está aprendendo prompts, velocidade significa **mais testes por minuto**.

Os modelos *de produção*

ID DO MODELO	VELOCIDADE (TOKENS/S)	CONTEXTO (TOKENS)	MÁX. DE SAÍDA
<code>openai/gpt-oss-120b</code> (usado no módulo)	500	131.072	65.536
<code>openai/gpt-oss-20b</code>	1000	131.072	65.536
<code>llama-3.3-70b-versatile</code>	280	131.072	32.768
<code>llama-3.1-8b-instant</code>	560	131.072	131.072

A lista completa e sempre atualizada está em `console.groq.com/docs/models` . Modelos **preview** servem para testes e podem sair do ar sem muito aviso.

O nome que vai no código é o **ID** exato, por exemplo `model="openai/gpt-oss-120b"` . Um ID errado devolve erro.

gpt-oss-120b: *pesos abertos* e raciocínio

- ✓ Modelo de **pesos abertos** da OpenAI, com 120 bilhões de parâmetros
- ✓ É um modelo de **raciocínio**: pensa antes de responder, e esse raciocínio também conta como tokens de saída
- ✓ O parâmetro `reasoning_effort` aceita `low`, `medium` (padrão) e `high`
- ✓ Janela de 131.072 tokens: cabem textos longos no prompt

A chamada que se repete em todo o módulo

```
chat_completion = client.chat.completions.create(
    messages=[
        {"role": "user",
         "content": "Me explique de forma reduzida o que são
as LLMs"}],
    model="openai/gpt-oss-120b",
)
print(chat_completion.choices[0].message.content)
```

Trecho do notebook da aula 04 (01-roles.ipynb).

Plano gratuito *e seus limites*

SIGLA	SIGNIFICA	GPT-0SS-120B*
RPM	Requisições por minuto	30
RPD	Requisições por dia	1.000
TPM	Tokens por minuto	8.000
TPD	Tokens por dia	200.000

* Tabela de limites de base da página Rate Limits, em outubro de 2026. Os da sua conta aparecem em console.groq.com/settings/limits.

- ✓ Os limites valem para a **organização**, não por pessoa
- ✓ Vale o que estourar primeiro: 30 pedidos pequenos em um minuto já batem no RPM
- ✓ Ao estourar, a API responde **429 Too Many Requests** e o cabeçalho `retry-after` diz quantos segundos esperar
- ✓ Planos pagos (Developer) liberam limites maiores

Para os notebooks do módulo, o plano gratuito sobra, desde que você não rode as células em laço.

A mesma API *de todo mundo*

SDK do Groq (o que o módulo usa)

```
from groq import Groq
client = Groq(api_key=...)
```

SDK da OpenAI apontando para o Groq

```
import openai
client = openai.OpenAI(
    base_url="https://api.groq.com/openai/v1",
    api_key=...,
)
```

- ✓ A API do Groq é "quase toda" compatível com a da OpenAI: mesma estrutura de `messages`, `choices` e parâmetros
- ✓ O que você aprender aqui (roles, temperatura, few shot...) vale para outras APIs de chat
- ✓ Diferenças documentadas: só `n=1`; `logprobs` e `logit_bias` não são aceitos; `temperature=0` vira `1e-8`

Por que o Groq *neste módulo*

RÁPIDO

Respostas em segundos deixam o ciclo escrever → rodar → comparar curto. É assim que se aprende prompt.

GRATUITO PARA COMEÇAR

Os limites do plano gratuito cobrem os exercícios do módulo.

MODELOS ABERTOS

gpt-oss, Llama e Qwen: técnicas testadas aqui funcionam com modelos que você também pode rodar em outros lugares.

API PADRÃO

Formato compatível com o da OpenAI: o código muda pouco se você trocar de provedor depois.

O foco do módulo é a **engenharia de prompt**. O Groq é o laboratório; as técnicas valem para qualquer LLM.

O que vem *no módulo*

02

Configuração do Ambiente

Chave da API, pasta, venv, bibliotecas e `.env`.

03

Introdução ao JupyterLab

Células, atalhos e kernel.

04

Roles · 05 Parâmetros · 06 Boas práticas

A base de toda chamada.

07

Output estruturado · 08 Condições

Controlar formato e comportamento.

09

Few shot · 10 Múltiplos passos · 11 CoT

Técnicas para tarefas difíceis.

12

Sumarização, complemento, transformação e análise de textos

Aplicações práticas (aulas 12 a 15) e o Guia da aula 16.

Teste o que *ficou*

1. O que o Groq oferece?

A) Treina modelos próprios

B) Executa (inferência) modelos de terceiros

C) Um editor de código

D) Um navegador

B.

2. A sigla RPM nos limites significa:

A) Rotações por minuto

B) Requisições por minuto

C) Respostas por modelo

D) Tokens por minuto

B.

3. Estourou o limite. A API devolve:

A) 200

B) 401

C) 404

D) 429

D. Too Many Requests.

4. Qual modelo os notebooks usam?

A) openai/gpt-oss-120b

B) gpt-4o

C) whisper-large-v3

D) claude

A.

Um laboratório *rápido e gratuito*

O Groq executa modelos abertos em chips próprios (LPU) com muitos tokens por segundo, tem plano gratuito com limites por minuto e por dia, e fala o mesmo formato de API da OpenAI. É o lugar ideal para testar prompts muitas vezes, com o `openai/gpt-oss-120b`.

Inferência

LPU

gpt-oss-120b

RPM · TPM · 429

API compatível

Próxima aula → 02 · Configuração do Ambiente

Fontes: console.groq.com/docs/quickstart; console.groq.com/docs/models; console.groq.com/docs/rate-limits; console.groq.com/docs/openai; console.groq.com/docs/api-reference (reasoning_effort); console.groq.com/docs/reasoning; groq.com (plataforma e LPU), consultados em outubro de 2026.