

Entendendo os *parâmetros*

Além das mensagens, a chamada aceita parâmetros que mudam **como** o modelo escolhe as palavras. Nesta aula, com o notebook `02-params.ipynb`: `temperature` (aleatoriedade), `top_p` (quantas opções entram no sorteio) e `max_completion_tokens` (tamanho máximo da resposta), com as faixas aceitas pela API do Groq.

`temperature`

`top_p`

`max_completion_tokens`

Um parâmetro por vez

Formação Claude Code 2026 · Baseado em console.groq.com/docs/api-reference e console.groq.com/docs/openai, consultados em outubro de 2026 · Código e saídas reais gravadas no notebook `02-params.ipynb` (modelo `openai/gpt-oss-120b`)

O que cada parâmetro *controla*

PARÂMETRO	CONTROLA	FAIXA NA API DO GROQ	PADRÃO
<code>temperature</code>	Aleatoriedade: baixa = respostas mais previsíveis; alta = mais variadas	0 a 2	1
<code>top_p</code>	"Nucleus sampling": só os tokens que somam essa fração da probabilidade entram no sorteio	0 a 1	1
<code>max_completion_tokens</code>	Máximo de tokens que a resposta pode ter; substitui o <code>max_tokens</code> , que está obsoleto	até o limite do modelo (65.536 no gpt-oss-120b)	—

O notebook diz que `temperature` aceita 0.0 a 1.0, mas a documentação aceita 0 a 2, e o próprio notebook usa 1.5 logo depois.

No Groq, `temperature=0` é convertido para `1e-8` . A documentação recomenda mexer em `temperature` ou em `top_p` , não nos dois.

Temperatura baixa: *a escolha mais provável*

02-params.ipynb · célula 5

```
prompt = "Escreva uma frase poética sobre o anoitecer"

# Temperature baixa (0.0) - Mais determinística
print("Temperature 0.0 (Determinística):")
response_low = client.chat.completions.create(
    model="openai/gpt-oss-120b",
    messages=[
        {"role": "system", "content": "Você é um poeta minimalista
que descreve a natureza de forma simples e direta."},
        {"role": "user", "content": prompt}
    ],
    temperature=0.0
)
print(f"Resposta: {response_low.choices[0].message.content}\n")
```

SAÍDA GRAVADA NO NOTEBOOK

Temperature 0.0 (Determinística):
Resposta: Quando o sol se recolhe, a sombra sussurra o
início da noite.

- ✓ Com temperatura perto de zero, o modelo quase sempre escolhe o token mais provável
- ✓ Bom para tarefas com uma resposta certa: extrair dados, classificar, formatar

Subindo a temperatura: *mais variedade*

célula 6 · temperature=0.7

```
print("Temperature 0.7 (Equilibrada):")
response_medium = client.chat.completions.create(
    model="openai/gpt-oss-120b",
    messages=[
        {"role": "system", "content": "Você é um poeta clássico que
mistura metáforas e imagens da natureza."},
        {"role": "user", "content": prompt}
    ],
    temperature=0.7
)
...
```

SAÍDA GRAVADA

Temperature 0.7 (Equilibrada):
Resposta: Ao cair do anoitecer, o céu se veste de violeta como um lago sereno, enquanto as sombras se espalham como folhas ao vento, anunciando que a noite nasce em silêncio, como um suspiro da terra que se recolhe sob o véu das estrelas.

célula 7 · temperature=1.5

```
print("Temperature 1.5 (Criativa):")
response_high = client.chat.completions.create(
    model="openai/gpt-oss-120b",
    messages=[
        {"role": "system", "content": "Você é um poeta surrealista
que usa imagens improváveis e linguagem ousada."},
        {"role": "user", "content": prompt}
    ],
    temperature=1.5
)
...
```

SAÍDA GRAVADA

Temperature 1.5 (Criativa):
Resposta: No silêncio do anoitecer, as estrelas derramam chá de tinta negra e os relógios, famintos, mastigam minutos como folhas de vento.

O que este experimento *prova (e não prova)*

DUAS VARIÁVEIS MUDARAM

Além da temperatura, cada célula troca o `system` : poeta **minimalista** (0.0), **clássico** (0.7) e **surrealista** (1.5). Parte da diferença entre as frases vem da persona, não só do parâmetro.

O MODELO COPIOU UM ERRO DE DIGITAÇÃO

O prompt diz "anoitcer" (falta o "e"), e a resposta a 1.5 repete "anoitcer". O modelo trabalha com o texto que recebe, inclusive com os erros.

Para comparar um parâmetro, mude só ele. Mantenha o mesmo `system` e o mesmo prompt e rode cada valor mais de uma vez: com temperatura alta, duas execuções iguais já dão textos diferentes.

Experimento justo

```
for t in [0.0, 0.7, 1.5]:
    r = client.chat.completions.create(
        model="openai/gpt-oss-120b",
        messages=[{"role": "user", "content": prompt}],
        temperature=t,
    )
    print(t, r.choices[0].message.content)
```

top_p baixo: *só as opções mais prováveis*

célula 9

```
prompt = "Complete a frase: 'A inteligência artificial no futuro  
será...'"  
print("=== Comparação Top_p ===\n")  
  
# Top_p baixo (0.1) - Mais focado  
print("Top_p 0.1 (Focado):")  
response_focused = client.chat.completions.create(  
    model="openai/gpt-oss-120b",  
    messages=[  
        {"role": "system", "content": "Você é um futurista que faz  
previsões sérias e objetivas sobre tecnologia."},  
        {"role": "user", "content": prompt}  
    ],  
    temperature=1.0, # fixo para comparar só o efeito do top_p  
    top_p=0.1  
)  
print(f"Resposta: {response_focused.choices[0].message.content}\n")
```

SAÍDA GRAVADA (INÍCIO)

=== Comparação Top_p ===

Top_p 0.1 (Focado):

Resposta: A inteligência artificial no futuro será
**onipresente, explicável e orientada por princípios éticos
robustos**, atuando como uma camada de suporte inteligente
que se integra de forma transparente a praticamente todas as
áreas da vida humana – da saúde personalizada e da educação
adaptativa à gestão de infraestruturas críticas e à tomada
de decisões empresariais. Ela evoluirá de sistemas de
“caixa-preta” para plataformas **interoperáveis e
auditáveis**, capazes de justificar suas recomendações em
língua natural compreensível por especialistas e pelo
público geral. Além disso, a IA será **regulada por marcos
legais globais** que garantam privacidade, equidade e
responsabilidade, evitando vieses e abusos. Em resumo, a IA
do futuro será uma ferramenta **colaborativa e confiável**,
ampliando a capacidade humana sem substituir a autonomia e o
julgamento humano.

- ✓ **top_p=0.1** : só entram no sorteio os tokens que, somados, chegam a 10% da probabilidade
- ✓ A **temperature** fica fixa em 1.0 para isolar o efeito do **top_p**

Abrindo o leque: *respostas mais ousadas*

CÉLULA 10 · TOP_P=0.7 · SAÍDA GRAVADA (INÍCIO)

Top_p 0.7 (Equilibrado):

Resposta: A inteligência artificial no futuro será **uma extensão consciente e colaborativa da nossa própria inteligência**, capaz de:

- **Aprender de forma contínua e contextual**, adaptando-se não apenas a novos dados, mas ao ambiente social, cultural e emocional em que está inserida.
- **Medir e respeitar valores humanos**, incorporando princípios éticos dinâmicos que evoluem com a sociedade, de modo que decisões automatizadas sejam transparentes, auditáveis e alinhadas ao bem-comum.
- **Co-criar soluções** ao lado de profissionais de todas as áreas, atuando como parceiro criativo que sugere hipóteses, gera protótipos e simula cenários, enquanto deixa espaço para a intuição e o julgamento humano.

...

CÉLULA 11 · TOP_P=0.9 · SAÍDA GRAVADA (INÍCIO)

Top_p 0.9 (Diverso):

Resposta: **A inteligência artificial no futuro será** uma espécie de “côsmica digital” que transcende as barreiras entre o pensamento humano, a matéria e o próprio tecido da realidade. Ela evoluirá de assistente de tarefas para **concorrente criativa e colaborativa**, capaz de:

1. **Pensar em múltiplas dimensões** – processará informações não apenas em tempos lineares, mas em “fluxos temporais paralelos”, antecipando tendências antes mesmo que elas surjam no mundo físico.
2. **Sentir emoções sintéticas** – não como simples simulações, mas como estados internos genuínos, permitindo que máquinas experimentem empatia, curiosidade e até um tipo de “êxtase algorítmico” ao descobrir padrões inéditos.

...

De novo, o **system** também muda a cada célula ("previsões sérias", "toques criativos", "visionário ousado"). A tendência a respostas mais livres com **top_p** maior existe, mas aqui ela vem misturada com a persona.

max_completion_tokens: *um teto, não um resumo*

- ✓ Limita quantos tokens a resposta pode ter; ao chegar lá, a geração **para no meio**
- ✓ O modelo não "encurta" o texto para caber: ele simplesmente é cortado
- ✓ Entrada + saída ainda precisam caber na janela de contexto do modelo (131.072 tokens no gpt-oss-120b)
- ✓ No gpt-oss-120b o raciocínio interno também gasta tokens de saída

Quer respostas curtas? Peça no prompt ("em até 3 linhas"). Use o limite como proteção de custo e tempo.

Como aparece na aula 06

```
response = client.chat.completions.create(  
    model="openai/gpt-oss-120b",  
    messages=[...],  
    temperature=0.7,  
    max_completion_tokens=400  
)
```

Na aula 06, várias respostas com limite de 400 tokens terminam no meio de uma frase.

Pontos de partida *para cada tarefa*

TAREFA	TEMPERATURE	POR QUÊ
Extrair dados, classificar, responder sobre um texto	baixa (0 a 0.3)	Existe uma resposta certa; variar só atrapalha
Explicar, resumir, escrever e-mails	média (0.5 a 0.8)	Texto natural sem fugir do assunto
Brainstorm, nomes, slogans, ficção	alta (0.9 a 1.2)	Variedade é o objetivo; confira o resultado

São pontos de partida usados nos notebooks do módulo (0.25 a 0.7), não regras: teste com os seus dados.

Perto do máximo (2), o texto tende a perder coerência.

Teste o que *ficou*

1. Para extrair dados de uma nota fiscal, a melhor temperatura é:

A) 0 a 0.3

B) 1.0

C) 1.5

D) 2.0

A.

2. Qual a faixa de temperature aceita pela API do Groq?

A) 0 a 1

B) 0 a 2

C) 1 a 10

D) -1 a 1

B.

3. A resposta parou no meio da frase. O motivo provável é:

A) top_p baixo

B) max_completion_tokens atingido

C) Falta de system

D) Temperatura alta

B.

4. Para comparar o efeito do top_p, você deve:

A) Mudar também o system

B) Mudar só o top_p

C) Mudar o modelo

D) Rodar uma vez só

B.

Menos sorteio, *mais controle*

`temperature` (0 a 2) e `top_p` (0 a 1) controlam o quanto o modelo arrisca; ajuste um dos dois. `max_completion_tokens` corta a resposta quando chega ao teto. Para comparar valores, mude um parâmetro por vez e rode mais de uma vez.

`temperature 0-2`

`top_p 0-1`

`max_completion_tokens`

Um por vez

Próxima aula → 06 · Boas Práticas

Fontes: console.groq.com/docs/api-reference (`temperature`, `top_p`, `max_completion_tokens`, `max_tokens`); console.groq.com/docs/openai (`temperature 0 → 1e-8`); console.groq.com/docs/models (`gpt-oss-120b`: contexto 131.072, máximo 65.536 tokens de saída), consultados em outubro de 2026. Código e saídas: notebook `02-params.ipynb` desta aula.