

Trabalhando com *sumarização*

Resumir é uma das tarefas mais úteis de um LLM e uma das mais traiçoeiras: o resumo precisa **encurtar sem inventar**. Nesta aula, com o notebook `09-sumarizacao.ipynb`: resumo proporcional, resumo em tópicos, resumo executivo, o mesmo texto em dois estilos e um resumo em JSON, conferindo cada resposta com o texto original.

Tamanho-alvo

Bullet points

Resumo executivo

Técnico × redes sociais

JSON

Fidelidade

Formação Claude Code 2026 · Baseado em console.groq.com/docs/api-reference (response_format), console.groq.com/docs/structured-outputs e no Guia de Engenharia de Prompt da aula 16, consultados em outubro de 2026 · Código e saídas reais gravadas no notebook `09-sumarizacao.ipynb` (modelo `openai/gpt-oss-120b`)

Resumo com *tamanho-alvo*

09-sumarizacao.ipynb · célula 3 (system e início do texto)

```
system_prompt = """
Você é um editor técnico especializado em jogos independentes.
Crie um resumo objetivo com aproximadamente 1/3 do tamanho do texto original,
preservando os pontos centrais e o tom informativo.
"""

user_prompt = """
A cena de jogos independentes segue em crescimento, com ferramentas como
engines gratuitas,
marketplaces digitais e financiamento coletivo tornando possível a criação
por equipes pequenas.
Desafios frequentes incluem descoberta (getting discovered) em lojas
saturadas, financiamento
...
```

- ✓ O tamanho vem como proporção: "aproximadamente 1/3 do tamanho do texto original"
- ✓ Temperatura 0.2: resumo é tarefa de fidelidade, não de criatividade

SAÍDA GRAVADA (COMPLETA)

```
=== Sumarização Básica ===
A cena indie cresce com engines gratuitas, marketplaces e
crowdfunding, permitindo equipes pequenas. Desafios
principais são descoberta em lojas saturadas, financiamento
pós-lançamento e equilibrar inovação e usabilidade. Estúdios
criam comunidades via early access/betas. Tendências:
narrativas curtas, jogos-como-serviço leves e áudio
procedural. O sucesso depende de qualidade, comunidade
engajada e estratégia de lançamento.
```

Contagem: o texto original tem 136 palavras; o resumo, 52 (38%). Perto do 1/3 pedido, e todos os pontos vêm do original.

Bullet points *e um número inventado*

célula 5

```
system_prompt = """
Você é um analista de políticas públicas. Gerei um resumo em bullet points
claros e hierárquicos:
- Destaque resultados (métricas)
- Liste problemas prioritários
- Sugira 3 ações imediatas e 2 ações estruturais
Mantenha frases curtas.
"""

user_prompt = """
Relatório Piloto: Nova rota de ciclovía e corredores de ônibus rápidos
implementada por 12 semanas.
Resultados preliminares: aumento no uso de bicicleta em 22% nas rotas
testadas; redução de tempo médio de deslocamento em ônibus local em 8%;
aumento de reclamações de comerciantes sobre estacionamento; registro de 3
incidentes leves envolvendo ciclistas.
Observações: infraestrutura temporária com sinalização provisória; campanhas
educativas em 4 bairros; orçamento limitado para fiscalização.
"""

...
```

"Gerei um resumo" no system é um erro de digitação do notebook (o pretendido é "Gere"); o modelo entendeu mesmo assim.

SAÍDA GRAVADA (INÍCIO)

```
=== Bullet Points (Mobilidade Urbana) ===
**Resultados (métricas)**
- Uso de bicicleta ↑ 22 % nas rotas testadas.
- Tempo médio de deslocamento de ônibus ↓ 8 %.
- Reclamações de comerciantes sobre estacionamento ↑ 15 %
(estimado).
...
```

O relatório diz só "aumento de reclamações de comerciantes".
O "↑ 15% (estimado)" foi criado pelo modelo. O prompt pedia
"destaque resultados (métricas)", e ele preencheu o que
faltava.

Correção no prompt: "use apenas números presentes no texto; se não houver,
escreva 'sem dado'".

Resumo *para quem decide*

célula 7

```
system_prompt = ""
Você é um consultor executivo. Construa um resumo executivo com:
1) Síntese em 2-3 frases
2) Principais métricas (visitantes, receita direta, parcerias)
3) 3 recomendações acionáveis para o próximo ano (priorizadas)
Seja conciso e orientado para decisão.
""

user_prompt = ""
Relatório: Festival "Olhar Curto" (3 dias).
Métricas: 4.200 visitantes (inclui sessões pagas e gratuitas), receita
direta: R$ 180.000 (ingressos + barra),
patrocínios: R$ 70.000, custos operacionais: R$ 150.000.
Impacto local: aumento de 18% no movimento de bares e cafés próximos durante
o evento;
envolvimento de 6 escolas técnicas; 25 curtas exibidos, 8 produções locais.
Desafios: logística de exibição ao ar livre (chuva reprogramou 2 sessões),
bilheteria online com alta taxa de desistência.
""
...
```

SAÍDA GRAVADA (SÍNTESE)

```
**Resumo Executivo - Festival "Olhar Curto" (3 dias)**

1. **Síntese**
O festival atraiu 4.200 visitantes, gerou R$ 180 mil em
receita direta e R$ 70 mil em patrocínios, resultando em
lucro líquido de aproximadamente R$ 100 mil após custos
operacionais de R$ 150 mil. O evento impulsionou o comércio
local (+18% de movimento em bares e cafés) e envolveu 6
escolas técnicas, mas enfrentou perdas de sessões por chuva
e alta taxa de desistência na bilheteria online.
...
```

- ✓ Conta conferida: 180 mil + 70 mil – 150 mil = **R\$ 100 mil**
- ✓ As três partes pedidas vieram: síntese, tabela de métricas e 3 recomendações priorizadas
- ✓ As recomendações trazem estimativas (+R\$ 30 mil...) que não estão no relatório: são projeções do modelo

O mesmo texto, *dois públicos*

célula 9 · os dois system prompts

```
system_prompt_tech = ""
Você é um redator técnico-científico. Produza um resumo formal
técnico (3-4 frases),
destacando metodologia, resultados quantitativos e limitações.
""

...

system_prompt_social = ""
Você é um comunicador digital. Faça uma versão curta e chamativa (1-2
frases) adequada para Instagram,
mantendo precisão mas com tom acessível e motivador.
""

...
```

CÉLULA 11 · REDES SOCIAIS (SAÍDA GRAVADA)

```
=== Resumo para Redes Sociais ===
Graças a sensores acústicos e à foto-identificação de tartarugas,
nossa costa viu a vida marinha crescer 12% em 2 anos e, com
pescadores parceiros, os emalhes caíram 35% - mas o plástico ainda
ameaça e o aquecimento traz branqueamento. Apoie a expansão das
estações e as campanhas de educação para proteger nosso futuro azul!
🌊🐢💙
```

CÉLULA 10 · TÉCNICO (SAÍDA GRAVADA)

```
=== Resumo Técnico ===
O projeto utilizou monitoramento trimestral de recifes por meio de
sensores acústicos acoplados a redes de hidrofones e
foto-identificação de tartarugas marinhas, integrando dados de
abundância e comportamento. Os resultados indicam uma recuperação
populacional de +12% nas duas primeiras temporadas, bem como uma
diminuição de 35% nos incidentes de emalhe graças à parceria com
pescadores locais, embora a carga de resíduos plásticos nas áreas de
alimentação tenha aumentado simultaneamente. As principais
limitações são a insuficiência de estações de monitoramento, a
dependência de financiamento externo para expansão da rede e a
vulnerabilidade a eventos de branqueamento associados ao aumento da
temperatura da água.
```

- ✓ Redes sociais: 2 frases, tom motivador, números corretos (12% em 2 anos, 35%)
- ✓ Técnico: o "resumo" tem **104 palavras**, mais que o texto original (74)
- ✓ Acrescentou "redes de hidrofones" e trocou "em 2 anos" por "nas duas primeiras temporadas"

Resumo em *JSON*

célula 13

```
json_prompt = f"""
Resuma o seguinte texto em JSON.
O JSON deve conter as chaves:
- "setores" (lista com os setores impactados)
- "beneficios" (lista com os principais beneficios citados)
- "desafios" (lista com os riscos ou preocupações levantadas)

Texto:
{texto}
"""

...
```

- ✓ As chaves são definidas no prompt: `setores`, `beneficios`, `desafios`
- ✓ O texto entra pela f-string `{texto}`

SAÍDA GRAVADA (INÍCIO)

```
=== RESUMO EM JSON ===
```json
{
 "setores": [
 "saúde",
 "finanças",
 "educação"
],
 ...
}
```

O conteúdo está fiel ao texto: três setores, quatro beneficios, três desafios.

## Parece JSON, *mas o Python não lê*

- ✓ A resposta começa com ````json` e termina com `````: as cercas de bloco de código do Markdown
- ✓ O notebook só imprime o texto, então ninguém percebe
- ✓ Mas, se o próximo passo for `json.loads(resposta_json)`, o programa quebra

JSON.LOADS NUMA RESPOSTA COM CERCAS - SAÍDA REAL

```
json.decoder.JSONDecodeError: Expecting value: line 1 column 1 (char 0)
```

Gerado com o mesmo formato de resposta, cercas incluídas.

Duas correções

```
response = client.chat.completions.create(
 model="openai/gpt-oss-120b",
 messages=[{"role": "user", "content": json_prompt}],
 response_format={"type": "json_object"}, # JSON válido
)
dados = json.loads(response.choices[0].message.content)
```

Ou peça no prompt "responda só com o JSON, sem crases" e remova as cercas no código antes do `json.loads`. O `response_format` (aula 07) é a forma garantida.

# Como pedir um resumo *que não invente*

- 1

Diga o tamanho

Proporção (1/3), frases (2-3) ou palavras (até 60). Confira contando.
- 2

Proíba acréscimos

"Use só informações do texto; não acrescente números nem fatos."
- 3

Trate o que falta

"Se uma métrica pedida não existir, escreva 'sem dado'."
- 4

Temperatura baixa

O notebook usa 0.15 a 0.25 para os resumos factuais.

CÉLULA	FIEL AO TEXTO?
3 · básica (1/3)	Sim
5 · tópicos	Inventou uma métrica (+15%)
7 · executivo	Sim; recomendações com projeções próprias
10 · técnico	Acrescentou detalhes e ficou maior que o original
11 · redes sociais	Sim
13 · JSON	Sim, mas com cercas de Markdown



## Resuma *e confira*

**Exercício:** escolha uma notícia ou um e-mail longo seu e peça três resumos: em 1 frase, em 3 tópicos e em JSON ( `assunto` , `decisoes` , `prazos` ).

```
system_prompt = """
Você resume textos com fidelidade.
Regras:
- Use apenas informações do texto
- Não acrescente números nem fatos
- Se algo pedido não existir, escreva "sem dado"
"""
```

- ✓ Marque no texto original de onde saiu cada informação do resumo
- ✓ Conte as palavras: o tamanho pedido foi respeitado?
- ✓ No JSON, use `response_format` e leia com `json.loads`
- ✓ Repita sem as regras do system e compare

## Teste o que *ficou*

1. O resumo em tópicos trouxe "↑ 15%" que não estava no texto. Isso é:

A) Um arredondamento

B) Uma informação inventada

C) Erro da API

D) Efeito do JSON

B.

2. Melhor temperatura para resumos factuais:

A) Baixa ( $\approx 0.2$ )

B) 1.0

C) 1.5

D) 2.0

A.

3. Por que o `json.loads` falharia na resposta da célula 13?

A) Chave errada

B) As cercas ``json antes do JSON

C) Acentos

D) Texto curto

B.

4. Para garantir JSON válido, use:

A) `max_completion_tokens`

B) `response_format`

C) `top_p`

D) Mais exemplos

B.

# Menor, *mas verdadeiro*

Um bom resumo tem tamanho definido, público definido e nenhuma informação nova. Diga o tamanho, proíba acréscimos, trate o que falta e use temperatura baixa. Para resumos que vão para outro programa, garanta o JSON com `response_format`.

1/3 · 2 frases · 60 palavras

Só o que está no texto

"sem dado"

`response_format`

Próxima aula → 13 · Complementando Textos

Fontes: [console.groq.com/docs/api-reference](https://console.groq.com/docs/api-reference) (`response_format`); [console.groq.com/docs/structured-outputs](https://console.groq.com/docs/structured-outputs); Guia de Engenharia de Prompt (aula 16), seções 15 e 19, consultados em outubro de 2026. Código e saídas: notebook `09-sumarizacao.ipynb` desta aula; contagens de palavras e contas conferidas à mão; `JSONDecodeError` gerado com Python 3.12.