

Terminologia em *IA Generativa*

Antes de decidir como usar IA generativa numa empresa, é preciso falar a mesma língua. Esta aula organiza os termos que aparecem em todo o módulo: **LLM**, **token**, **janela de contexto**, **prompt**, **temperatura**, **embedding**, **RAG**, **alucinação**, **agente** e outros, cada um com uma definição curta e um exemplo.

IA × ML × deep learning

LLM

Token

Contexto

Embedding


RAG

Alucinação

Agente

Formação Claude Code 2026 · Baseado no glossário da documentação da Anthropic (docs.anthropic.com), na documentação do Groq e na página de modelos da Anthropic, consultados em outubro de 2026 · Exemplo de tokens testado com tiktoken em [exemplos/](#)

Do conceito amplo *ao específico*



LLM e *modelo de fundação*

- ✓ **LLM** (*Large Language Model*, modelo de linguagem de grande porte): modelo com muitos parâmetros, treinado em grande volume de texto, que consegue resumir, responder, traduzir e escrever código (definição do glossário da Anthropic)
- ✓ **Parâmetros**: os números ajustados no treino; é neles que o "conhecimento" do modelo fica guardado. Um modelo "de 120 bilhões de parâmetros" tem 120 bilhões desses números
- ✓ **Modelo de fundação**: um modelo treinado de forma ampla, que serve de base para muitas tarefas, em vez de uma tarefa só

EXEMPLO	QUEM FAZ	TIPO
Claude (Fable, Opus, Sonnet, Haiku)	Anthropic	Proprietário
gpt-oss-120b	OpenAI	Pesos abertos
Llama 3.3 70B	Meta	Pesos abertos

Modelos citados na documentação do Groq e da Anthropic, consultadas em outubro de 2026. A aula 02 explica a diferença entre os tipos.

O modelo não lê palavras, *lê tokens*

tokens.py

```
# pip install tiktoken
import tiktoken

enc = tiktoken.get_encoding("cl100k_base")

frases = [
    "The cat sat on the mat.",
    "O gato sentou no tapete.",
    "Inteligência artificial generativa",
    "anticonstitucionalissimamente",
]

for f in frases:
    ids = enc.encode(f)
    pedacos = [enc.decode([i]) for i in ids]
    print(f"{len(f):>3} caracteres -> {len(ids):>2} tokens")
    print("    ", pedacos)
```

SAÍDA

```
23 caracteres -> 7 tokens
['The', ' cat', ' sat', ' on', ' the', ' mat',
'.']
24 caracteres -> 9 tokens
['O', ' g', 'ato', ' sent', 'ou', ' no', ' tap',
'ete', '.']
34 caracteres -> 6 tokens
['Int', 'elig', 'ência', ' artificial', ' gener',
'ativa']
29 caracteres -> 8 tokens
['ant', 'icon', 'stit', 'uc', ' ional', 'iss',
'im', 'amente']
```

- ✓ Token é o menor pedaço que o modelo processa: palavra, parte de palavra, caractere ou byte
- ✓ A frase em português usou **9 tokens** contra **7** da equivalente em inglês, neste tokenizador (`cl100k_base`)
- ✓ Para o Claude, um token vale cerca de 3,5 caracteres em inglês; varia com o idioma (glossário da Anthropic)

Janela de contexto: a *memória de trabalho*

- ✓ É o quanto de texto o modelo consegue "ter diante de si" ao responder: prompt, histórico, documentos colados e a resposta
- ✓ Não é a base de treino: é uma memória de trabalho, que se esvazia quando a conversa acaba (glossário da Anthropic)
- ✓ A soma de entrada e saída precisa caber na janela (documentação do Groq)

Contexto grande não é de graça: mais tokens enviados significam mais custo e mais tempo por chamada.

MODELO	CONTEXTO	SAÍDA MÁX.
gpt-oss-120b (Groq)	131.072	65.536
Llama 3.3 70B (Groq)	131.072	32.768
Claude Haiku 4.5	200 mil	64 mil
Claude Sonnet 5.5, Opus 5.5, Fable 5.1	1 milhão	128 mil

Valores em tokens, das páginas de modelos do Groq e da Anthropic em outubro de 2026.

Prompt, system prompt *e temperatura*

PROMPT

A instrução enviada ao modelo, mais o contexto e os exemplos que a acompanham. Escrever bem o prompt é a **engenharia de prompt** (módulo 39).

SYSTEM PROMPT

As regras permanentes da conversa: papel, tom, limites. Fica separado da pergunta do usuário e vale para todas as respostas.

TEMPERATURA

Controla a aleatoriedade: baixa deixa as respostas conservadoras; alta, mais variadas (glossário da Anthropic). No Groq vai de 0 a 2.

Inferência é o nome do ato de usar o modelo já treinado para responder a um prompt. Cada chamada à API é uma inferência (aula 04).

Pré-treino, fine-tuning e *alinhamento*

1

Pré-treino (*pretraining*)

O modelo aprende a prever a próxima palavra em um corpus enorme de texto. Sozinho, ainda não é bom em seguir instruções (glossário da Anthropic).

2

Fine-tuning

Treino adicional com dados específicos, para o modelo imitar os padrões desse conjunto: um estilo, um formato, um domínio.

3


Alinhamento com feedback humano

Pessoas avaliam respostas e o modelo é ajustado para seguir melhor a intenção do usuário. No estudo do InstructGPT, as respostas de um modelo de 1,3 bilhão de parâmetros foram preferidas às do GPT-3 de 175 bilhões.

Fonte do 3º passo: Ouyang et al., "Training language models to follow instructions with human feedback" (arXiv:2203.02155).

Embedding, busca semântica e *RAG*

- ✓ **Embedding:** representação de um texto como uma lista de números que codifica o *sentido*; textos parecidos ficam próximos
- ✓ **Busca semântica:** achar trechos pelo significado, não só por palavras iguais
- ✓ **RAG** (*retrieval augmented generation*): combinar busca de informação com geração, passando os trechos achados na janela de contexto para que a resposta se apoie em evidência (glossário da Anthropic)



A aula 09 mostra um RAG funcionando, passo a passo.

Alucinação: *plausível, mas falso*

- ✓ Alucinação é quando o modelo produz uma afirmação **fluente e convincente que não corresponde à realidade**: um número, uma citação, um fato
- ✓ O modelo foi treinado para gerar texto plausível, não para consultar uma base de fatos: por isso o erro aparece com a mesma confiança do acerto
- ✓ Reduz com: dar o material (RAG), pedir "use apenas o texto fornecido", temperatura baixa e verificação

Já vimos isso no módulo 39. Num resumo, o modelo escreveu "reclamações ↑ 15%" sem esse número existir no relatório; numa expansão, atribuiu um teste a 2022 que foi divulgado em 2019.

Regra de empresa: tudo que o modelo afirma e que importa para uma decisão tem **fonte** ou passa por **conferência humana**.

Ferramenta, agente *e multimodal*

FERRAMENTA (TOOL)

Uma função que o modelo pode pedir para executar: buscar um pedido, consultar um banco, enviar um e-mail. O modelo decide *qual* e com *quais argumentos*.

AGENTE

Sistema em que o LLM usa ferramentas em laço, com base no que observa do ambiente, até concluir a tarefa (definição da Anthropic; aula 10).

MULTIMODAL

Modelo que entende ou gera mais de um tipo de dado: texto, imagem, áudio, vídeo. Ex.: transcrever áudio ou descrever uma foto.

Latência é o tempo entre enviar o prompt e receber a resposta; **custo** é cobrado por tokens de entrada e de saída. Os dois pesam em qualquer projeto (aulas 02 e 04).

Glossário *de bolso*

TERMO	EM UMA FRASE	AULA
LLM	Modelo de linguagem de grande porte, treinado em muito texto	01
Token	Menor unidade de texto que o modelo processa	01
Janela de contexto	Quanto texto cabe de uma vez (entrada + saída)	01
Inferência	Usar o modelo treinado para responder	04
Benchmark	Teste padronizado para comparar modelos	03
Fine-tuning	Treino extra com dados específicos	04
Embedding	Números que representam o sentido de um texto	09
RAG	Buscar trechos e entregá-los ao modelo para responder	09
Alucinação	Resposta fluente, porém falsa	08
Workflow	Sequência de passos definida pelo código	10
Agente	LLM que escolhe os próprios passos e ferramentas	10

Teste o que *ficou*

1. Um token é:

A) Sempre uma palavra inteira

B) O menor pedaço de texto que o modelo processa

C) Um parâmetro

D) Uma chave de API

B.

2. A janela de contexto limita:

A) Só o tamanho do prompt

B) Entrada e saída juntas

C) Só a resposta

D) O número de usuários

B.

3. RAG serve para:

A) Treinar um modelo do zero

B) Entregar ao modelo trechos relevantes para ele responder

C) Aumentar a temperatura

D) Trocar de idioma

B.

4. Uma resposta fluente, mas falsa, é chamada de:

A) Inferência

B) Embedding

C) Alucinação

D) Benchmark

C.

A mesma língua, *antes de decidir*

IA generativa cria conteúdo; LLMs fazem isso com tokens, dentro de uma janela de contexto limitada; o prompt e a temperatura guiam a resposta; RAG e ferramentas ligam o modelo a dados e ações; e a alucinação é o risco que obriga a conferir. Com esse vocabulário, o resto do módulo fica mais fácil.

LLM

Token

Contexto

Inferência

RAG

Alucinação

Agente

Próxima aula → 02 · Modelos LLM (Open Source, Proprietários)

Fontes: docs.anthropic.com/en/docs/about-claude/glossary (LLM, tokens, janela de contexto, temperatura, pré-treino, fine-tuning, RAG); docs.anthropic.com/en/docs/about-claude/models/overview; console.groq.com/docs/models e [/api-reference](https://console.groq.com/docs/api-reference); arxiv.org/abs/2203.02155; anthropic.com/engineering/building-effective-agents, consultados em outubro de 2026. O exemplo `tokens.py` usa tiktoken (`cl100k_base`) e foi executado para esta aula.