

Modelos LLM: *abertos e proprietários*

Escolher um modelo é uma decisão de negócio, não só técnica. Nesta aula: o que significa "aberto" de verdade, o que são **pesos abertos**, como são os modelos proprietários por API, quanto cada um custa para um mesmo volume de uso e quais critérios usar para decidir (privacidade, custo, personalização, desempenho, suporte e risco de depender de um fornecedor).

Open source

Pesos abertos

Proprietário

Custo por token

Critérios de escolha

Híbrido

Formação Claude Code 2026 · Baseado na Open Source AI Definition 1.0 (opensource.org), no cartão do modelo gpt-oss-120b (huggingface.co/openai), na página de modelos da Anthropic e na do Groq, consultados em outubro de 2026 · Preços mudam: confira nas páginas dos provedores

Onde o modelo *roda e de quem é*

PROPRIETÁRIO (FECHADO)

O fabricante guarda o modelo. Você usa por **API** ou por um produto e paga por uso. Exemplo: a família Claude, da Anthropic.

- + desempenho de ponta, sem infraestrutura, suporte
- dados passam pelo fornecedor, pouco controle, risco de dependência

PESOS ABERTOS (OPEN WEIGHTS)

Os **pesos** (os números do modelo) estão disponíveis para baixar, rodar e, em geral, ajustar. Exemplos: gpt-oss, da OpenAI, e Llama, da Meta.

- + controle, privacidade, personalização, custo previsível
- você cuida da operação ou paga um hospedeiro

Os dois tipos podem ser usados por API. A diferença está em **quem controla** o modelo e **onde** ele roda, e não em "ser uma API".

"Open source" e "pesos abertos" *não são a mesma coisa*

- ✓ A **Open Source AI Definition 1.0**, da Open Source Initiative, exige quatro liberdades: **usar** para qualquer fim, **estudar** e inspecionar, **modificar** e **compartilhar**
- ✓ Para exercer essas liberdades, a definição pede três coisas sob licenças aprovadas: **informação sobre os dados** de treino, o **código** de treino e execução e os **parâmetros** do modelo
- ✓ Muitos modelos só liberam os parâmetros (e a licença). Esses são "pesos abertos", não "open source" pela definição

ITEM	OPEN SOURCE (OSAID)	PESOS ABERTOS	PROPRIETÁRIO
Parâmetros	Sim	Sim	Não
Código de treino	Sim	Nem sempre	Não
Info dos dados	Sim	Em geral não	Não
Rodar em casa	Sim	Sim	Não

As linhas "nem sempre" e "em geral não" dependem de cada modelo: leia o cartão e a licença. A tabela resume a definição da OSI.

gpt-oss: um modelo *de pesos abertos*

GPT-0SS-120B

117B

parâmetros no total, 5,1B ativos
por token

GPT-0SS-20B

21B

parâmetros no total, 3,6B ativos

- ✓ Licença **Apache 2.0**: uso comercial livre, sem copyleft
- ✓ "Parâmetros ativos" menores que o total: é uma arquitetura que usa só parte do modelo a cada token, o que reduz o custo de rodar
- ✓ Com quantização MXFP4, o 120b roda em **uma GPU de 80 GB** e o 20b cabe em **16 GB** de memória
- ✓ Esforço de raciocínio configurável (baixo, médio, alto) e acesso ao raciocínio completo

Fonte: cartão do modelo openai/gpt-oss-120b no Hugging Face. É o mesmo modelo usado no módulo 39, hospedado no Groq.

A família Claude *por API*

MODELO	INDICADO PARA	PREÇO (US\$ POR MILHÃO DE TOKENS)	CONTEXTO
Claude Fable 5.1	Raciocínio exigente e trabalho agêntico longo	10 entrada · 50 saída	1 mi
Claude Opus 5.5	Programação e trabalho de conhecimento de longa duração	4 entrada · 20 saída	1 mi
Claude Sonnet 5.5	Melhor combinação de velocidade e inteligência	2 entrada · 10 saída	1 mi
Claude Haiku 4.5	O mais rápido, com inteligência próxima da de ponta	1 entrada · 5 saída	200 mil

Uma família com vários tamanhos permite escolher por tarefa: o maior para raciocínio difícil, o menor para volume e velocidade.

Modelos têm data de aposentadoria. A página da Anthropic indica, por exemplo, que o Haiku 4.5 não será retirado antes de 15/10/2026 e o Sonnet 5.5, não antes de 28/09/2027. Planeje a migração.

Fonte: docs.anthropic.com/en/docs/about-claude/models/overview, outubro de 2026.

O mesmo volume, *preços diferentes*

Cenário hipotético: um sistema que processa, por mês, **100 milhões de tokens de entrada e 20 milhões de saída**.

MODELO (VIA)	ENTRADA	SAÍDA	TOTAL/MÊS
gpt-oss-120b (Groq)	0,15	0,60	US\$ 27
Claude Haiku 4.5	1	5	US\$ 200
Claude Sonnet 5.5	2	10	US\$ 400
Claude Opus 5.5	4	20	US\$ 800
Claude Fable 5.1	10	50	US\$ 2.000

- ✓ Conta: $(100 \times \text{preço de entrada}) + (20 \times \text{preço de saída})$, com preços em US\$ por milhão de tokens
- ✓ A diferença entre o mais barato e o mais caro é de **quase 75 vezes** (27 contra 2.000)
- ✓ **Preço não é qualidade:** o barato pode bastar para classificar e resumir; o caro pode compensar em tarefas difíceis
- ✓ Rodar o modelo aberto em casa troca o preço por token por **GPUs, energia e equipe**

Preço do gpt-oss-120b no Groq (US\$ 0,15 entrada / US\$ 0,60 saída) e dos modelos Claude, nas páginas dos provedores em outubro de 2026. Os volumes são fictícios.

Três jeitos de *usar um modelo*

JEITO	COMO FUNCIONA	CONTROLE DE DADOS	ESFORÇO
API do fabricante	Envia o prompt à nuvem do dono do modelo (ex.: Claude pela Anthropic)	Depende do contrato	Baixo
Hospedeiro de modelo aberto	Um terceiro roda o modelo aberto e vende acesso por API (ex.: gpt-oss no Groq)	Depende do contrato	Baixo
Infraestrutura própria	Você baixa os pesos e roda em servidores seus ou numa nuvem sua	Máximo	Alto

O mesmo modelo aberto pode ser usado nos três últimos modos; o proprietário só no primeiro (ou em nuvens parceiras do fabricante, como Amazon Bedrock, Google Cloud e Microsoft Foundry, que a Anthropic lista na página de modelos).

Como decidir *com uma matriz*

CRITÉRIO	PERGUNTA	TENDE A FAVORECER
Privacidade e conformidade	Os dados podem sair da empresa?	Aberto em infraestrutura própria
Desempenho	A tarefa exige o melhor modelo disponível?	Proprietário de ponta (teste: aula 03)
Custo	Qual o volume e o crescimento esperados?	Depende: baixo volume → API; alto e estável → avaliar aberto
Personalização	Precisa ajustar o modelo (fine-tuning)?	Aberto
Esforço e equipe	Existe time para operar GPUs e atualizar?	API
Dependência	E se o preço subir ou o modelo for retirado?	Aberto reduz; usar camada de abstração reduz nos dois

Matriz de apoio à decisão elaborada para esta aula a partir das diferenças descritas nas seções anteriores; os pesos de cada critério são da sua empresa.


Leia a licença *antes de adotar*

- ✓ **Permissiva** (ex.: Apache 2.0, a do gpt-oss): uso comercial livre, inclusive modificar e redistribuir, sem copyleft e com concessão de patentes
- ✓ **Licenças próprias do fabricante**: algumas famílias de pesos abertos trazem condições de uso, limites ou políticas de uso aceitável. Leia antes de colocar em produto
- ✓ "Gratuito para baixar" não significa "gratuito para qualquer uso"

Peça ao jurídico para revisar a licença de qualquer modelo que vá para um produto, e registre **qual modelo, qual versão e qual licença** cada sistema usa.

Isso também vale para os **dados**: a licença do modelo não resolve a origem do que você envia a ele (aula 08).

O padrão *híbrido*



Compare *dois modelos*

Exercício: escolha uma tarefa real da sua empresa (ex.: responder dúvidas de clientes) e preencha a matriz abaixo para dois modelos.

CRITÉRIO	MODELO A	MODELO B
Qualidade em 20 exemplos seus		
Custo estimado por mês		
Latência média		
Dados saem da empresa?		
Licença / contrato		

- ✓ Use o mesmo prompt nos dois (módulo 39) e o mesmo conjunto de teste
- ✓ Calcule o custo com a fórmula da seção 05 e o seu volume real
- ✓ A aula 03 mostra por que 20 exemplos servem para comparar, mas não para concluir quem é "melhor"

Teste o que *ficou*

1. "Pesos abertos" significa que:

A) O modelo é sempre open source pela OSI

B) Os parâmetros estão disponíveis para baixar

C) O modelo não custa nada

D) Os dados de treino são públicos

B. Open source pela OSI exige também dados e código.

2. Para dados que não podem sair da empresa, tende a servir melhor:

A) Qualquer API

B) Modelo aberto em infraestrutura própria

C) Nenhum modelo

D) O modelo mais caro

B.

3. O menor custo por token garante:

A) A melhor qualidade

B) Nada: é preciso testar qualidade, latência e risco

C) Menos alucinação

D) Mais privacidade

B.

4. Para trocar de modelo sem reescrever o sistema, você usa:

A) Temperatura maior

B) Uma camada de abstração

C) Mais tokens

D) Um prompt maior

B.

Escolha por tarefa, *não por moda*

Modelos proprietários entregam desempenho e simplicidade por API; modelos de pesos abertos entregam controle e custo previsível, com mais trabalho de operação. "Open source" tem definição própria, e a licença importa. Decida por uma matriz de critérios, teste com os seus dados e mantenha o código pronto para trocar de modelo.

Pesos abertos × proprietário

Custo por milhão de tokens

Licença

Matriz de critérios

Camada de abstração

Próxima aula → 03 · Benchmark entre Modelos LLM

Fontes: opensource.org/ai/open-source-ai-definition (OSAID 1.0); huggingface.co/openai/gpt-oss-120b; docs.anthropic.com/en/docs/about-claude/models/overview; console.groq.com/docs/models, consultados em outubro de 2026. Os totais mensais da seção 05 foram calculados para um volume hipotético.