

Benchmark entre *modelos LLM*

Todo lançamento de modelo vem com uma tabela de benchmarks. Saber ler essa tabela, e saber o que ela **não** diz, evita escolher o modelo errado. Nesta aula: o que é um benchmark, os mais conhecidos (MMLU, SWE-bench, Chatbot Arena), por que os números enganam (contaminação, amostra pequena) e como montar um teste com os dados da sua empresa.

MMLU

SWE-bench

Chatbot Arena

Contaminação

Intervalo de confiança

Benchmark próprio

Formação Claude Code 2026 · Baseado em [arxiv.org](#) (MMLU, Chatbot Arena, estudo de contaminação), [swebench.com](#) e no AI Index 2025 da Stanford, consultados em outubro de 2026 · Exemplo estatístico executado em [exemplos/](#)

Um benchmark é *uma prova padronizada*

CONJUNTO DE TAREFAS

perguntas,
problemas, issues



REGRA DE CORREÇÃO

gabarito, testes ou
votos



MÉTRICA

% de acerto ou nota

O que o benchmark mede é o desempenho naquela prova, naquelas condições (prompt, temperatura, número de tentativas). Não é o desempenho na *sua* tarefa.

- ✓ Todos os modelos fazem a **mesma prova**, o que permite comparar
- ✓ O resultado é um número (ex.: 82% de acerto), fácil de pôr numa tabela, mas fácil de ler errado

Por isso a tabela do fabricante é ponto de partida para escolher quem testar, e não o resultado da escolha.

Quatro benchmarks *que você vai encontrar*

BENCHMARK	O QUE MEDE	COMO PONTUA
MMLU	Conhecimento geral e resolução de problemas em 57 tarefas (matemática básica, história dos EUA, ciência da computação, direito...)	% de respostas de múltipla escolha corretas
GPQA e MMMU	Perguntas de nível avançado de ciência e perguntas multimodais (texto e imagem); o AI Index 2025 os cita entre os benchmarks exigentes de 2023	% de acerto
SWE-bench	Resolver issues reais do GitHub de 12 repositórios Python, editando o código	% de issues resolvidas (testes passam)
Chatbot Arena	Preferência humana: duas respostas anônimas, a pessoa escolhe a melhor	Ranking a partir dos votos

Fontes: Hendrycks et al. (arXiv:2009.03300); swebench.com; Chiang et al. (arXiv:2403.04132); AI Index Report 2025 (Stanford HAI).

O que cada tipo *revela*

CONHECIMENTO E RACIOCÍNIO

Múltipla escolha com gabarito (MMLU, GPQA). Barato de rodar e comparar; mede o que o modelo *sabe*, não o que ele *entrega* num fluxo real.

CÓDIGO E TAREFAS COMPLETAS

SWE-bench: o modelo precisa entender um repositório e produzir uma correção que passe nos testes. Mais próximo do trabalho real.

PREFERÊNCIA HUMANA

Chatbot Arena: reflete o que as pessoas *gostam* de ler (clareza, tom, formatação), que nem sempre é o mais correto.

OS SEUS DADOS

Um conjunto de exemplos da **sua** tarefa, com a resposta esperada. É o único que mede o que importa para você (seção 08).

Como funciona *o Chatbot Arena*

1

Uma pergunta, dois modelos anônimos

A pessoa escreve o que quiser e recebe duas respostas, sem saber qual modelo gerou cada uma.

2

Voto

Ela escolhe a melhor. Só depois os nomes aparecem.

3

Ranking estatístico

Milhares de comparações aos pares viram uma pontuação por modelo.

- ✓ No artigo de apresentação (março de 2024), a plataforma já tinha mais de **240 mil votos**
- ✓ Vantagem: perguntas variadas, feitas por usuários reais, e sem gabarito decorável
- ✓ Limite: quem vota é quem usa o site, e as perguntas não são as da sua empresa

Fonte: Chiang et al., "Chatbot Arena: An Open Platform for Evaluating LLMs by Human Preference" (arXiv:2403.04132). A tabela atual fica em lmarena.ai.

SWE-bench: *problemas de verdade*

- ✓ As tarefas vêm de **issues do GitHub** de 12 repositórios Python
- ✓ Há versões: **Verified** (500 instâncias filtradas por humanos), **Lite** (300, mais barata de rodar), **Multilingual** (300 tarefas de 42 repositórios em 9 linguagens) e outras
- ✓ No site, o padrão de comparação roda todos os modelos no mesmo ambiente (mini-SWE-agent), para o resultado depender do modelo e não da ferramenta

A lição do SWE-bench vale para qualquer benchmark: **o ambiente conta**. O mesmo modelo, com outra ferramenta ao redor (agente, número de tentativas, ferramentas), dá outro resultado.

Fonte: swebench.com, outubro de 2026.

Por que o número *pode enganar*

CONTAMINAÇÃO

Se as perguntas da prova apareceram no treino, o modelo "decorou" parte dela. Um estudo (arXiv:2311.09783) destaca que o problema é crítico em modelos fechados e em alguns abertos, onde faltam dados sobre o treino.

SATURAÇÃO

Quando os melhores modelos já acertam quase tudo, o benchmark deixa de separar os bons dos ótimos. Por isso surgem provas mais difíceis, como as de 2023 citadas no AI Index.

SENSÍVEL AO PROMPT

Mudar a redação, a ordem das opções ou o número de exemplos pode alterar o resultado. Compare só resultados obtidos com o **mesmo** método.

AMOSTRA PEQUENA

Com poucas perguntas, uma diferença de alguns pontos pode ser sorte. A próxima seção mostra isso com números.

Quantas perguntas *bastam* para comparar?

avaliar.py · intervalo de confiança

```
def wilson(acertos, n, z=1.96):
    """Intervalo de confiança de 95% para uma proporção."""
    p = acertos / n
    d = 1 + z * z / n
    centro = (p + z * z / (2 * n)) / d
    folga = z * math.sqrt(p * (1 - p) / n + z * z / (4 * n * n)) / d
    return centro - folga, centro + folga

def simular(taxa_real, n, semente):
    rnd = random.Random(semente)
    return sum(rnd.random() < taxa_real for _ in range(n))
```

A comparação

```
# Dois modelos fictícios: A acerta 70% e B acerta 75% de verdade
for n in (40, 1000):
    a = simular(0.70, n, 1)
    b = simular(0.75, n, 2)
    print(f"--- benchmark com {n} perguntas ---")
    for nome, ac in (("A", a), ("B", b)):
        lo, hi = wilson(ac, n)
        print(f"modelo {nome}: {ac / n:.1%} (IC 95%: {lo:.1%} a {hi:.1%})")
```

SAÍDA

```
--- benchmark com 40 perguntas ---
modelo A: 75.0% (IC 95%: 59.8% a 85.8%)
modelo B: 75.0% (IC 95%: 59.8% a 85.8%)
--- benchmark com 1000 perguntas ---
modelo A: 67.4% (IC 95%: 64.4% a 70.2%)
modelo B: 75.1% (IC 95%: 72.3% a 77.7%)
```

- ✓ **Simulação:** A acerta de verdade 70% e B, 75%
- ✓ Com 40 perguntas, os dois deram 75% e o intervalo vai de 60% a 86%: não dá para distinguir
- ✓ Com 1.000, os intervalos se separam (A: 64 a 70%; B: 72 a 78%)

Monte um teste *com os seus dados*

1

Colete casos reais

30 a 100 exemplos da tarefa, incluindo os difíceis e os casos de borda.

2

Defina a resposta certa

Gabarito, regra automática ou nota de um revisor, com critérios escritos.

3

Rode todos do mesmo jeito

Mesmo prompt, mesma temperatura, mais de uma execução.

4

Meça além do acerto

Custo por tarefa, latência, formato válido, taxa de recusa.

Guarde o conjunto de teste. Ele serve para decidir hoje e para reavaliar quando sair um modelo novo, ou quando o atual for retirado (aula 02).

Revise as respostas erradas à mão: muitas vezes o "erro" revela um prompt ruim ou um gabarito mal escrito, não um modelo fraco.

Antes de acreditar *numa tabela de benchmark*

PERGUNTA	POR QUE IMPORTA
Quem mediu: o fabricante ou um terceiro?	Resultados do próprio fabricante usam as condições mais favoráveis
Com qual prompt, quantos exemplos e quantas tentativas?	Os resultados só são comparáveis com o mesmo método
Quantas perguntas tem a prova?	Poucas perguntas = diferença que pode ser ruído
A prova pode ter vazado para o treino?	Contaminação infla o resultado
Mede o tipo de tarefa que eu faço?	Conhecimento geral não prevê desempenho em atendimento, jurídico ou código
E custo e latência?	O "melhor" modelo pode ser lento e caro demais para o seu caso

Teste o que *ficou*

1. O SWE-bench avalia modelos em:

A) Perguntas de múltipla escolha

B) Issues reais do GitHub

C) Traduções

D) Preferência de leitores

B.

2. Contaminação de um benchmark acontece quando:

A) A prova foi vista no treino

B) O modelo é lento

C) O prompt é longo

D) Há erro de rede

A.

3. Dois modelos empatam em 75% numa prova de 40 perguntas. Você conclui:

A) São idênticos

B) Não dá para distinguir: o intervalo é largo

C) O primeiro é melhor

D) O segundo é melhor

B.

4. O melhor critério para escolher um modelo é:

A) A tabela do fabricante

B) O teste com os seus próprios dados

C) O modelo mais novo

D) O mais caro

B.

Meça o que *importa para você*

Benchmarks públicos ajudam a escolher quem testar, mas sofrem de contaminação, saturação, sensibilidade ao prompt e amostras pequenas. O teste decisivo é o seu: casos reais, mesma condição para todos, mais de uma execução e métricas de custo e latência, com um intervalo de confiança antes de declarar um vencedor.

MMLU

SWE-bench

Chatbot Arena

Contaminação

IC 95%

Teste próprio

Próxima aula → 04 · Treinamento × Inferência

Fontes: arxiv.org/abs/2009.03300 (MMLU); arxiv.org/abs/2403.04132 (Chatbot Arena); arxiv.org/abs/2311.09783 (contaminação); swebench.com; hai.stanford.edu/ai-index/2025-ai-index-report, consultados em outubro de 2026. O exemplo `avaliar.py` é uma simulação com taxas de acerto escolhidas por nós.