

Tomada de decisão *com IA*

Usar IA para decidir não é entregar a decisão ao modelo: é desenhar **quem faz o quê**. Esta aula mostra os níveis de autonomia, como escolher quais decisões delegar, o papel da pessoa no processo, o **viés de automação**, por que as explicações de um modelo podem enganar, como usar o **limiar de confiança** para dividir o trabalho entre IA e pessoas e o que registrar para poder contestar e auditar.

Níveis de autonomia

Humano no ciclo

Viés de automação

Explicações que enganam

Limiar de confiança

Registro

Formação Claude Code 2026 · Baseado em Turpin et al. (arXiv:2305.04388), Kadavath et al. (arXiv:2207.05221), no NIST AI RMF 1.0 (Govern 3.2) e na LGPD (art. 20), consultados em outubro de 2026 · Simulação executada em [exemplos/](#)

Quatro níveis *de delegação*

NÍVEL	O QUE A IA FAZ	QUEM DECIDE	EXEMPLO
1 · Informar	Resume, organiza, busca	A pessoa	Resumo do histórico do cliente antes do atendimento
2 · Recomendar	Sugere uma ação, com as razões	A pessoa	Sugere resposta; o atendente edita e envia
3 · Decidir com aprovação	Prepara a decisão completa	A pessoa aprova, caso a caso	Monta o reembolso; o analista confirma
4 · Decidir sozinha	Decide e executa	A IA, com auditoria depois	Classificar um e-mail como spam

A maior parte dos casos úteis fica nos níveis 1 a 3. O nível 4 só cabe em decisões de baixo impacto, fáceis de desfazer e bem avaliadas.

Quais decisões *entregar à IA*

CARACTERÍSTICA	MAIS SEGURO DELEGAR	MANTER COM PESSOAS
Impacto de um erro	Baixo	Alto (saúde, crédito, emprego)
Reversibilidade	Fácil de desfazer	Irreversível
Volume	Muito alto	Poucos casos
Critério	Regra clara e verificável	Julgamento, valores, exceções
Qualidade medida	Testada com dados reais (aula 03)	Sem avaliação

- ✓ Quanto mais as colunas da esquerda dominam, mais alto o nível de autonomia que se justifica
- ✓ Decisões que afetam pessoas (crédito, contratação, perfil) pedem cuidado legal: pela **LGPD, art. 20**, o titular pode pedir **revisão por pessoa natural** de decisões tomadas unicamente por tratamento automatizado que afetem seus interesses

Quadro de apoio elaborado para esta aula. Fonte do art. 20: planalto.gov.br (Lei 13.709/2018).

O papel da pessoa *precisa ser definido*

NO CICLO (IN THE LOOP)

A pessoa aprova cada decisão antes de ela valer. Mais seguro, mais lento.

SOBRE O CICLO (ON THE LOOP)

A IA decide; a pessoa monitora, amostra e intervém quando preciso. Escala melhor.

FORA DO CICLO

Nenhuma supervisão em tempo real, só auditoria posterior. Reserve para o de menor risco.

O NIST AI RMF pede políticas e procedimentos que **definam e diferenciem papéis e responsabilidades** nas configurações humano-IA e na supervisão dos sistemas (Govern 3.2).

"Tem um humano revisando" só protege se a pessoa **tem tempo, informação e autoridade** para discordar. Revisão de fachada é risco, não controle.

Confiar *demais* na máquina

- ✓ O **viés de automação** é a tendência de aceitar o que a ferramenta indica sem conferir; tende a acontecer quando a pessoa fica num papel de observação, com poder de decidir mas apoiada em um auxílio automático
- ✓ Vai de situações graves (piloto automático) a banais (aceitar toda correção do corretor ortográfico)
- ✓ Uma IA que escreve com fluência e confiança **reforça** esse efeito

CONTRAMEDIDA	COMO
Mostrar a evidência	Junto da sugestão, as fontes e os trechos que a sustentam (RAG, aula 09)
Pedir uma decisão ativa	A pessoa escolhe e justifica, em vez de só clicar em "aceitar"
Medir o override	Se ninguém nunca discorda da IA, algo está errado
Treinar	Mostrar casos em que a IA erra com confiança (aula 08)

Conceito descrito na literatura de fatores humanos; resumo conforme a página "Automation bias" da Wikipédia. Contramedidas: síntese desta aula.

A justificativa do modelo *pode não ser a razão*

- ✓ É tentador ler o raciocínio passo a passo (CoT, aula 11 do módulo 39) como o processo real do modelo, o que daria transparência
- ✓ Turpin et al. mostram que as explicações em CoT **podem deturpar a verdadeira razão** da resposta
- ✓ Ao inserir um viés na entrada (ex.: reordenar as opções para a resposta ser sempre "(A)"), os modelos mudavam de resposta **sem mencionar** o viés e, quando levados a respostas erradas, **racionalizavam** o erro
- ✓ A acurácia caiu até **36%** em 13 tarefas do BIG-Bench Hard (GPT-3.5 e Claude 1.0)

Consequência para decisões: uma explicação fluente *não prova* que a recomendação está certa. É plausível, e pode ser enganosa.

Trate a explicação como **hipótese a verificar**: confira os fatos citados e se as razões batem com os dados, não só se "soam bem".

Fonte: arxiv.org/abs/2305.04388. Modelos testados na época do estudo; o princípio de verificar vale para os atuais.

O modelo sabe *o quanto confia* na resposta?

- ✓ Kadavath et al. (2022) estudaram se modelos conseguem avaliar a validade das próprias afirmações
- ✓ Mostraram que modelos maiores são **bem calibrados** em perguntas de múltipla escolha e de verdadeiro/falso quando apresentadas no formato certo
- ✓ Calibrado quer dizer: quando diz ter 80% de confiança, acerta cerca de 80% das vezes
- ✓ Propuseram pedir que o modelo proponha uma resposta e depois estime a probabilidade **P(True)** de ela estar correta

Não dá para supor calibração. Ela depende do modelo, do formato e da tarefa. Antes de usar a "confiança" para decidir, **meça** com os seus dados: a taxa de acerto de cada faixa de confiança bate com o valor declarado?

Fonte: arxiv.org/abs/2207.05221 ("Language Models (Mostly) Know What They Know").

Um limiar que divide *o trabalho*

limiar_de_confianca.py · simulação

```
rnd = random.Random(7)
casos = []
for _ in range(1000):
    confianca = rnd.choice([0.55, 0.65, 0.75, 0.85, 0.95, 0.98])
    acertou = rnd.random() < confianca    # suposicao: confianca
    calibrada
    casos.append((confianca, acertou))

print("limiar | decide sozinha | erros nesses | vai para pessoa")
for limiar in (0.5, 0.8, 0.9, 0.97):
    auto = [c for c in casos if c[0] >= limiar]
    erros = sum(1 for _, ok in auto if not ok)
    print(f"{limiar:>6.2f} | {len(auto) / len(casos):>13.0%} | "
          f"{erros / len(auto):>11.1%} | {1 - len(auto) /
len(casos):>14.0%}")
```

SAÍDA

limiar	decide sozinha	erros nesses	vai para pessoa
0.50	100%	20.1%	0%
0.80	51%	8.0%	49%
0.90	33%	4.6%	67%
0.97	18%	1.7%	82%


Simulação com 1.000 casos fictícios; supõe confiança calibrada (a verificar na vida real).

Autonomia *contra* erro

LIMIAR	IA DECIDE	ERRO NESSES	VAI PARA PESSOAS
0,50	100%	20,1%	0%
0,80	51%	8,0%	49%
0,90	33%	4,6%	67%
0,97	18%	1,7%	82%

- ✓ Subir o limiar **reduz o erro** das decisões automáticas, mas **manda mais trabalho para pessoas**
- ✓ Não existe limiar "certo": ele depende do **custo de um erro** e da **capacidade de revisão** da equipe
- ✓ Mesmo com 0,97, ainda restam 1,7% de erros nas decisões automáticas: auditoria por amostragem contínua necessária

Desenhe a decisão *de ponta a ponta*



- ✓ Casos de **baixa confiança** ou de **alto risco** vão para pessoas, sempre
- ✓ A pessoa vê a sugestão e a evidência
- ✓ O que a pessoa decide **volta** como dado: serve para avaliar e melhorar
- ✓ Há um caminho para o **afetado contestar** a decisão

O que guardar *e o que medir*

Registro de cada decisão

- ✓ Dados usados (ou referência a eles) e versão do modelo e do prompt
- ✓ Sugestão da IA, confiança e evidência mostrada
- ✓ Decisão final, quem decidiu e quando
- ✓ Se a pessoa discordou da IA, e por quê

Cuidado com a privacidade dos registros: minimize dados pessoais e defina prazo de guarda (aula 08).

MÉTRICA	MOSTRA
Taxa de acerto por faixa de confiança	Se a confiança é confiável
Cobertura automática	Quanto a IA decide sem pessoas
Taxa de override	Quanto as pessoas discordam (e se acertam)
Erros por tipo de caso	Onde a IA falha mais
Tempo até a decisão	Ganho de velocidade
Contestações	Impacto percebido pelos afetados

Escolha o *nível de autonomia*

Exercício: para cada decisão, indique o nível (1 a 4) e justifique com as características da seção 02.

- ✓ Classificar a prioridade de um chamado de suporte
- ✓ Aprovar um desconto de até 5% a um cliente
- ✓ Selecionar candidatos para uma entrevista
- ✓ Sugerir o texto de uma resposta a uma reclamação
- ✓ Bloquear uma transação suspeita de fraude

Pista: onde o erro é caro, difícil de desfazer ou afeta pessoas (candidatos, fraude), a autonomia deve ser **menor** (mais supervisão). Onde é barato e reversível, pode ser maior.

Para cada caso, defina também a **métrica** que mostrará, depois de rodar, se o nível escolhido foi adequado.

Teste o que *ficou*

1. Subir o limiar de confiança faz:

A) Mais casos irem para pessoas e menos erro nos automáticos

B) Mais erro

C) Nenhum efeito

D) Acabar com a revisão

A.

2. Viés de automação é:

A) Aceitar a indicação da ferramenta sem conferir

B) Um erro de rede

C) Um tipo de prompt

D) Um limite de tokens

A.

3. A explicação passo a passo do modelo:

A) É sempre a razão real

B) Pode ser plausível e enganosa: verifique os fatos

C) Dispensa conferência

D) É proibida

B.

4. Pela LGPD (art. 20), o titular pode pedir:

A) Revisão por pessoa natural de decisão só automatizada

B) Que a IA seja desligada

C) O código do modelo

D) Nada

A.

A IA recomenda, *o processo decide*

Defina o nível de autonomia pelo impacto e pela reversibilidade de cada decisão, desenhe o papel da pessoa para que ela possa realmente discordar, combata o viés de automação com evidência, trate explicações como hipóteses, ajuste o limiar de confiança medindo a calibração e registre tudo para auditar e permitir contestação.

4 níveis

Humano no ciclo

Viés de automação

Explicação ≠ prova

Limiar

Registro

Próxima aula → 12 · Ideias em Projetos de IA

Fontes: arxiv.org/abs/2305.04388; arxiv.org/abs/2207.05221; airc.nist.gov/airmf-resources/airmf/5-sec-core (Govern 3.2); planalto.gov.br (Lei 13.709/2018, art. 20); en.wikipedia.org/wiki/Automation_bias, consultados em outubro de 2026. A simulação `limiar_de_confianca.py` usa dados fictícios e foi executada para esta aula.