

GUIA PRÁTICO

Instalando o Ollama no Linux

Passo a passo para instalar, configurar e testar o Ollama em distribuições Linux, incluindo execução como serviço systemd e primeiros comandos com modelos locais.

Material de apoio · Claude Code (Gratuito) com Ollama
Instalando e Configurando Ollama

1. O que é o Ollama

O Ollama é uma ferramenta que permite baixar, executar e gerenciar modelos de linguagem (LLMs) localmente na sua máquina, sem depender de serviços em nuvem. Ele expõe uma API HTTP local (por padrão na porta 11434) que pode ser usada por outras ferramentas, como o Claude Code, para conversar com modelos rodando no seu próprio computador.

Requisitos mínimos

Linux 64 bits (x86_64 ou ARM64), pelo menos 8 GB de RAM para modelos pequenos (7B), acesso à internet para baixar os modelos e, opcionalmente, uma GPU NVIDIA/AMD compatível para acelerar a inferência.

2. Instalação rápida (script oficial)

A forma mais simples de instalar o Ollama no Linux é usando o script de instalação oficial, que detecta sua distribuição, baixa o binário correto e configura o serviço automaticamente.

- 1 Abra um terminal e execute o comando abaixo:

```
curl -fsSL https://ollama.com/install.sh | sh
```

- 2 Digite sua senha quando solicitado (o script usa sudo para instalar o binário em /usr/local/bin e configurar o serviço).
- 3 Ao final, o script inicia automaticamente o serviço ollama via systemd, deixando a API disponível em `http://localhost:11434`.

Se você tiver GPU NVIDIA

O script detecta drivers NVIDIA/CUDA já instalados e habilita a aceleração por GPU automaticamente. Se o Ollama não reconhecer a GPU, verifique se o driver NVIDIA e o `nvidia-container-toolkit` (quando usar Docker) estão atualizados.

3. Instalação manual (tarball)

Caso prefira não executar o script, ou esteja em um ambiente sem systemd (por exemplo, um container), é possível instalar manualmente a partir do pacote .tgz.

- 1 Baixe o pacote compactado (ajuste a arquitetura se necessário):

```
curl -L https://ollama.com/download/ollama-linux-amd64.tgz -o ollama-linux-amd64.tgz
```

- 2 Extraia o conteúdo em /usr:

```
sudo tar -C /usr -xzf ollama-linux-amd64.tgz
```

- 3 Confirme que o binário foi instalado corretamente:

```
ollama --version
```

- 4 Para rodar o Ollama como serviço em segundo plano nesse cenário manual, inicie o servidor diretamente:

```
ollama serve
```

Deixe esse comando rodando em um terminal (ou use nohup / tmux / screen para mantê-lo ativo).

4. Configurando o Ollama como serviço systemd

Quando instalado pelo script oficial em uma distribuição com systemd, o Ollama já é registrado como serviço. Os comandos abaixo ajudam a gerenciá-lo.

COMANDO	O QUE FAZ
<code>sudo systemctl status ollama</code>	Verifica se o serviço está ativo
<code>sudo systemctl start ollama</code>	Inicia o serviço
<code>sudo systemctl stop ollama</code>	Para o serviço
<code>sudo systemctl enable ollama</code>	Habilita início automático no boot
<code>journalctl -u ollama -f</code>	Acompanha os logs em tempo real

Configurações via variáveis de ambiente

Para alterar host/porta ou outras opções, crie um arquivo de override do systemd:

```
sudo systemctl edit ollama
```

E adicione, por exemplo:

```
[Service]
Environment="OLLAMA_HOST=0.0.0.0:11434"
```

Depois recarregue e reinicie:

```
sudo systemctl daemon-reload
sudo systemctl restart ollama
```

5. Testando a instalação

- 1 Baixe e execute um modelo pequeno para testar, por exemplo o Llama 3.2:

```
ollama run llama3.2
```

Na primeira execução, o modelo será baixado automaticamente (pode levar alguns minutos, dependendo do tamanho e da sua conexão).

- 2 Depois do download, um prompt interativo abrirá. Teste com uma pergunta simples:

```
>>> Explique o que é o Ollama em uma frase.
```

Para sair do modo interativo, digite /bye.

- 3 Verifique se a API está respondendo corretamente:

```
curl http://localhost:11434/api/tags
```

6. Comandos essenciais do dia a dia

COMANDO	DESCRIÇÃO
ollama list	Lista os modelos já baixados localmente
ollama pull <modelo>	Baixa um modelo sem executá-lo
ollama run <modelo>	Executa um modelo em modo interativo
ollama ps	Mostra os modelos atualmente carregados em memória
ollama rm <modelo>	Remove um modelo baixado
ollama show <modelo>	Exibe detalhes/parâmetros de um modelo

7. Atualizando o Ollama

Para atualizar para a versão mais recente, basta executar novamente o script de instalação oficial — ele detecta a instalação existente e substitui apenas o binário:

```
curl -fsSL https://ollama.com/install.sh | sh
```

8. Desinstalando o Ollama

- 1 Pare e desabilite o serviço:

```
sudo systemctl stop ollama
sudo systemctl disable ollama
```

- 2 Remova o binário, o serviço e o usuário criado pela instalação:

```
sudo rm /etc/systemd/system/ollama.service
sudo rm $(which ollama)
sudo rm -r /usr/share/ollama
sudo userdel ollama
sudo groupdel ollama
```

- 3 (Opcional) Remova os modelos baixados:

```
sudo rm -rf /usr/share/ollama/.ollama/models
```

9. Solução de problemas comuns

Erro "connection refused" ao acessar a API

O serviço não está rodando. Verifique com `sudo systemctl status ollama` e inicie com `sudo systemctl start ollama`, ou execute `ollama serve` manualmente.

Porta 11434 já em uso

Outro processo pode estar usando a porta. Verifique com `sudo lsof -i :11434` e finalize o processo conflitante, ou altere a variável `OLLAMA_HOST` para outra porta.

GPU não detectada

Confirme os drivers com `nvidia-smi` (NVIDIA) e reinicie o serviço após instalar/atualizar os drivers. O Ollama também funciona normalmente em modo CPU, apenas com desempenho mais baixo.