

## GUIA PRÁTICO

# Instalando o Ollama no Linux

Passo a passo para instalar, configurar e testar o Ollama em distribuições Linux, incluindo execução como serviço systemd e primeiros comandos com modelos locais.

---

Material de apoio · Claude Code (Gratuito) com Ollama  
Instalando e Configurando Ollama

## 1. O que é o Ollama

O Ollama é uma ferramenta que permite baixar, executar e gerenciar modelos de linguagem (LLMs) localmente na sua máquina, sem depender de serviços em nuvem. Ele expõe uma API HTTP local (por padrão na porta `11434`) que pode ser usada por outras ferramentas, como o Claude Code, para conversar com modelos rodando no seu próprio computador.

### Requisitos mínimos

Linux 64 bits (x86\_64 ou ARM64), pelo menos 8 GB de RAM para modelos pequenos (7B), acesso à internet para baixar os modelos e, opcionalmente, uma GPU NVIDIA/AMD compatível para acelerar a inferência.

## 2. Instalação rápida (script oficial)

A forma mais simples de instalar o Ollama no Linux é usando o script de instalação oficial, que detecta sua distribuição, baixa o binário correto e configura o serviço automaticamente.

- 1 Abra um terminal e execute o comando abaixo:

```
curl -fsSL https://ollama.com/install.sh | sh
```

- 2 Digite sua senha quando solicitado (o script usa `sudo` para instalar o binário em `/usr/local/bin` e configurar o serviço).

- 3 Ao final, o script inicia automaticamente o serviço `ollama` via `systemd`, deixando a API disponível em `http://localhost:11434`.

### Se você tiver GPU NVIDIA

O script detecta drivers NVIDIA/CUDA já instalados e habilita a aceleração por GPU automaticamente. Se o Ollama não reconhecer a GPU, verifique se o driver NVIDIA e o `nvidia-container-toolkit` (quando usar Docker) estão atualizados.

### 3. Instalação manual (tarball)

---

Caso prefira não executar o script, ou esteja em um ambiente sem `systemd` (por exemplo, um container), é possível instalar manualmente a partir do pacote `.tgz`.

- 1 Baixe o pacote compactado (ajuste a arquitetura se necessário):

```
curl -L https://ollama.com/download/ollama-linux-amd64.tgz -o ollama-linux-amd64.tgz
```

- 2 Extraia o conteúdo em `/usr`:

```
sudo tar -C /usr -xzf ollama-linux-amd64.tgz
```

- 3 Confirme que o binário foi instalado corretamente:

```
ollama --version
```

- 4 Para rodar o Ollama como serviço em segundo plano nesse cenário manual, inicie o servidor diretamente:

```
ollama serve
```

Deixe esse comando rodando em um terminal (ou use `nohup` / `tmux` / `screen` para mantê-lo ativo).

## 4. Configurando o Ollama como serviço systemd

Quando instalado pelo script oficial em uma distribuição com `systemd`, o Ollama já é registrado como serviço. Os comandos abaixo ajudam a gerenciá-lo.

| Comando                                   | O que faz                          |
|-------------------------------------------|------------------------------------|
| <code>sudo systemctl status ollama</code> | Verifica se o serviço está ativo   |
| <code>sudo systemctl start ollama</code>  | Inicia o serviço                   |
| <code>sudo systemctl stop ollama</code>   | Para o serviço                     |
| <code>sudo systemctl enable ollama</code> | Habilita início automático no boot |
| <code>journalctl -u ollama -f</code>      | Acompanha os logs em tempo real    |

### Configurações via variáveis de ambiente

Para alterar host/porta ou outras opções, crie um arquivo de override do systemd:

```
sudo systemctl edit ollama
```

E adicione, por exemplo:

```
[Service]
Environment="OLLAMA_HOST=0.0.0.0:11434"
```

Depois recarregue e reinicie:

```
sudo systemctl daemon-reload
sudo systemctl restart ollama
```

## 5. Testando a instalação

- 1 Baixe e execute um modelo pequeno para testar, por exemplo o Llama 3.2:

```
ollama run llama3.2
```

Na primeira execução, o modelo será baixado automaticamente (pode levar alguns minutos, dependendo do tamanho e da sua conexão).

- 2 Depois do download, um prompt interativo abrirá. Teste com uma pergunta simples:

```
>>> Explique o que é o Ollama em uma frase.
```

Para sair do modo interativo, digite `/bye`.

- 3 Verifique se a API está respondendo corretamente:

```
curl http://localhost:11434/api/tags
```

## 6. Comandos essenciais do dia a dia

| Comando                                 | Descrição                                          |
|-----------------------------------------|----------------------------------------------------|
| <code>ollama list</code>                | Lista os modelos já baixados localmente            |
| <code>ollama pull &lt;modelo&gt;</code> | Baixa um modelo sem executá-lo                     |
| <code>ollama run &lt;modelo&gt;</code>  | Executa um modelo em modo interativo               |
| <code>ollama ps</code>                  | Mostra os modelos atualmente carregados em memória |
| <code>ollama rm &lt;modelo&gt;</code>   | Remove um modelo baixado                           |
| <code>ollama show &lt;modelo&gt;</code> | Exibe detalhes/parâmetros de um modelo             |

## 7. Atualizando o Ollama

Para atualizar para a versão mais recente, basta executar novamente o script de instalação oficial — ele detecta a instalação existente e substitui apenas o binário:

```
curl -fsSL https://ollama.com/install.sh | sh
```

## 8. Desinstalando o Ollama

---

- 1 Pare e desabilite o serviço:

```
sudo systemctl stop ollama
sudo systemctl disable ollama
```

- 2 Remova o binário, o serviço e o usuário criado pela instalação:

```
sudo rm /etc/systemd/system/ollama.service
sudo rm $(which ollama)
sudo rm -r /usr/share/ollama
sudo userdel ollama
sudo groupdel ollama
```

- 3 (Opcional) Remova os modelos baixados:

```
sudo rm -rf /usr/share/ollama/.ollama/models
```

## 9. Solução de problemas comuns

---

### Erro "connection refused" ao acessar a API

O serviço não está rodando. Verifique com `sudo systemctl status ollama` e inicie com `sudo systemctl start ollama`, ou execute `ollama serve` manualmente.

### Porta 11434 já em uso

Outro processo pode estar usando a porta. Verifique com `sudo lsof -i :11434` e finalize o processo conflitante, ou altere a variável `OLLAMA_HOST` para outra porta.

### GPU não detectada

Confirme os drivers com `nvidia-smi` (NVIDIA) e reinicie o serviço após instalar/atualizar os drivers. O Ollama também funciona normalmente em modo CPU, apenas com desempenho mais baixo.