

GUIA PRÁTICO

Baixando Modelos no Ollama

Como encontrar, baixar, escolher variantes e gerenciar modelos de linguagem localmente com o Ollama.

Material de apoio · Claude Code (Gratuito) com Ollama
Baixando Modelos no Ollama

1. Onde encontrar modelos

Todos os modelos oficiais do Ollama ficam catalogados em ollama.com/library. Lá é possível ver a lista completa de modelos disponíveis, suas variantes de tamanho (parâmetros), níveis de quantização e o tamanho aproximado de download de cada uma.

Nome do modelo e "tag"

Um modelo é identificado como nome:tag, por exemplo llama3.2:3b. Quando a tag é omitida (ex.: `ollama pull llama3.2`), o Ollama usa a tag `latest`, que normalmente aponta para a variante padrão recomendada pelo autor do modelo.

2. Baixando um modelo com ollama pull

O comando `pull` baixa o modelo para o disco local sem executá-lo, útil para preparar modelos com antecedência ou em scripts de automação.

- 1 Baixe a versão padrão de um modelo:

```
ollama pull llama3.2
```

- 2 Para baixar uma variante específica (tamanho de parâmetros), informe a tag:

```
ollama pull llama3.2:1b  
ollama pull llama3.2:3b
```

- 3 Acompanhe o progresso do download diretamente no terminal — o Ollama mostra a barra de progresso por camada (layer) do modelo, pois cada modelo é baixado em partes reaproveitáveis.

Baixar e conversar em um único comando

Se o modelo ainda não existir localmente, `ollama run <modelo>` baixa automaticamente antes de abrir o modo interativo. Use `ollama pull` quando quiser apenas baixar, sem iniciar uma conversa.

3. Escolhendo o tamanho e a quantização certos

A maioria dos modelos populares (Llama, Qwen, Gemma, Mistral, etc.) possui várias variantes. Escolher a variante certa é um equilíbrio entre qualidade de resposta, velocidade e memória disponível.

PARÂMETROS	RAM/VRAM RECOMENDADA	USO TÍPICO
1B – 3B	4–8 GB	Respostas rápidas, tarefas simples, hardware limitado
7B – 8B	8–16 GB	Bom equilíbrio entre qualidade e desempenho
13B – 14B	16–32 GB	Maior qualidade, exige mais memória
30B+	32 GB+ (idealmente GPU dedicada)	Tarefas complexas, raciocínio avançado

Além do tamanho, os nomes das tags também podem indicar o nível de quantização (compressão), como q4_0 ou q8_0. Quantizações menores (ex.: q4) reduzem o uso de memória e aceleram a inferência, com uma pequena perda de qualidade em relação a q8 ou ao modelo em precisão original.

```
ollama pull qwen2.5:7b-instruct-q4_0
```

Cuidado com o espaço em disco

Modelos maiores podem ocupar de 4 GB a mais de 40 GB cada. Verifique o tamanho listado em ollama.com/library antes de baixar variantes grandes.

4. Listando e inspecionando modelos baixados

- 1 Veja todos os modelos já baixados na sua máquina:

```
ollama list
```

- 2 Consulte detalhes de um modelo específico (parâmetros, licença, template de prompt, etc.):

```
ollama show llama3.2
```

- 3 Veja quais modelos estão atualmente carregados em memória:

```
ollama ps
```

5. Atualizando um modelo já baixado

Quando o autor publica uma nova versão sob a mesma tag, basta rodar o pull novamente — o Ollama baixa apenas as camadas que mudaram:

```
ollama pull llama3.2
```

6. Removendo modelos

Para liberar espaço em disco, remova modelos que não estão mais em uso:

```
ollama rm llama3.2:1b
```

Confira o espaço usado

Combine `ollama list` com o tamanho de cada modelo para decidir quais remover antes de baixar variantes maiores.

7. Baixando modelos de outras fontes (GGUF / Hugging Face)

Além da biblioteca oficial, o Ollama também importa modelos no formato GGUF hospedados no Hugging Face, úteis para modelos ainda não publicados em ollama.com/library.

- 1 Baixe diretamente de um repositório Hugging Face compatível:

```
ollama pull hf.co/<usuario>/<repositorio-gguf>
```

- 2 Também é possível criar um modelo customizado localmente a partir de um arquivo .gguf já baixado, usando um Modelfile:

```
FROM ./meu-modelo.gguf

ollama create meu-modelo -f Modelfile
```

8. Solução de problemas comuns

Download muito lento ou interrompido

O `ollama pull` pode ser executado novamente para retomar de onde parou, já que o download é feito por camadas (layers) individuais.

Erro de espaço em disco insuficiente

Verifique o espaço livre com `df -h` e remova modelos não utilizados com `ollama rm` antes de baixar novos.

Modelo não encontrado

Confirme o nome exato e a tag em ollama.com/library; nomes de modelo diferenciam maiúsculas/minúsculas em alguns casos e a tag `latest` nem sempre corresponde ao maior modelo disponível.