

Os Modelos do Claude

Fable · Opus · Sonnet · Haiku. Diferenças, capacidades e aplicabilidade de cada modelo — e como escolher o certo para cada tarefa.

 Fable 5

 Opus 4.8

 Sonnet 5

 Haiku 4.5

A família Claude

Modelos projetados para diferentes necessidades de desempenho e custo. Um mesmo cérebro, calibrado em pontos diferentes do espectro.

● FRONTEIRA

Fable 5

Máxima capacidade. O mais poderoso — para os problemas mais difíceis e trabalho agêntico de longo horizonte.

● FLAGSHIP

Opus 4.8

Alto desempenho. Coding agêntico e tarefas complexas de alto valor, com grande autonomia.

● EQUILÍBRIO

Sonnet 5

O mais versátil. Equilíbrio ideal entre inteligência e velocidade para o uso diário.

● VELOCIDADE

Haiku 4.5

Rápido & econômico. O mais rápido e barato — perfeito para tarefas simples em tempo real.

← mais capaz · mais rápido e acessível →

Para que serve cada um

● FABLE 5 — MÁXIMA INTELIGÊNCIA

O modelo de fronteira: raciocínio profundo, execução autônoma de longo horizonte e os problemas mais difíceis que os outros modelos não resolvem sozinhos.

● SONNET 5 — O EQUILÍBRIO PERFEITO

Qualidade quase-Opus em coding e tarefas agênticas, com velocidade e custo muito menores. O cavalo de batalha da produção.

● OPUS 4.8 — CODING AGÊNTICO DE PONTA

Flagship altamente autônomo — estado da arte em trabalho de conhecimento, memória e execução multi-passo de alto valor.

● HAIKU 4.5 — VELOCIDADE MÁXIMA

Assistentes e chatbots empresariais, geração e revisão de código em produção, automação de fluxos, análise e classificação de conteúdo em alto volume.

Comparativo de características

DIMENSÃO	 FABLE 5	 OPUS 4.8	 SONNET 5	 HAIKU 4.5
Inteligência	★★★★★	★★★★★	★★★★☆	★★★☆☆
Velocidade	★★☆☆☆	★★★☆☆	★★★★☆	★★★★★
Contexto	1M tokens	1M tokens	1M tokens	200K tokens
Preço (in / out por 1M)	\$10 / \$50	\$5 / \$25	\$3 / \$15	\$1 / \$5
Raciocínio complexo	Excepcional	Excepcional	Muito bom	Básico
Ideal para	Fronteira / autonomia	Alto valor	Maioria dos casos	Alto volume

 Todos os modelos atuais suportam raciocínio adaptativo e 1M de contexto (exceto Haiku, 200K).

Raciocínio adaptativo

Os modelos alocam tokens de "pensamento" de forma dinâmica. Você não define um orçamento fixo — o modelo decide quanto refletir.

⚡ Pergunta simples

"Qual a capital da França?" → resposta instantânea, sem gastar raciocínio.

🧩 Problema complexo

"Prove este teorema" → o modelo ativa milhares de tokens de reflexão antes de responder.



Na prática: effort alto (high/xhigh) para coding e tarefas agênticas complexas; effort baixo para respostas rápidas e sensíveis a latência. O modelo interliga o raciocínio entre chamadas de ferramentas automaticamente. O parâmetro **effort** vai de low a max, ajustando profundidade vs. custo.

Como escolher o modelo certo

● Use Fable 5 quando...

O problema está no limite do que a IA consegue · a tarefa é um agente autônomo rodando por horas · você quer a maior taxa de acerto possível e o custo é secundário · precisa de delegação confiável a múltiplos sub-agentes.

● Use Opus 4.8 quando...

A precisão é crítica (medicina, direito, finanças) · a tarefa exige coding agêntico e raciocínio em vários passos · você precisa de alta autonomia e memória entre sessões · qualidade importa mais que custo.

● Use Sonnet 5 quando...

Você quer o melhor equilíbrio custo/desempenho · aplicações empresariais de médio a alto volume · análise de código e desenvolvimento ágil · a maioria dos casos de uso em produção.

● Use Haiku 4.5 quando...

Volume muito alto de requisições simples · latência é o fator mais importante · orçamento limitado · tarefas bem definidas e diretas · pipelines de dados automatizados.

Custo & contexto

Preço por 1 milhão de tokens (entrada / saída). Mais capaz = mais caro — escolha por adequação, não por reflexo.

 FABLE 5

\$10 / \$50

1M de contexto · pensamento sempre ativo. Para o topo da dificuldade.

 OPUS 4.8

\$5 / \$25

1M de contexto sem prêmio de contexto longo. Flagship autônomo.

 SONNET 5

\$3 / \$15

1M de contexto. Melhor ROI da produção.

 HAIKU 4.5

\$1 / \$5

200K de contexto. Viabiliza altíssimo volume.



Dica de custo: combine prompt caching (até ~90% de economia em contexto repetido) e batching (~50%). E lembre: um Sonnet bem usado costuma bater um Opus mal-orientado.

Teste rápido

Você precisa classificar 5 milhões de mensagens de suporte por sentimento, com latência mínima e orçamento apertado. Qual modelo?

A) Fable 5

B) Opus 4.8

C) Sonnet 5

D) Haiku 4.5

Resposta: D — Haiku 4.5. Classificação de sentimento é uma tarefa simples e bem definida; o que domina é volume, latência e custo. Fable ou Opus resolveriam, mas seriam caros e lentos demais para 5M de itens. Escolha o menor modelo que faz o trabalho bem.

RECAPITULANDO

A escolha certa para cada desafio

Não existe "melhor modelo" — existe o modelo adequado à tarefa. Comece pelo menor que resolve bem e suba de tier só quando precisar.

● Fronteira

● Alto valor

● Produção

● Escala

PRÓXIMA AULA → CLAUDE API × AGENTS SDK: COMO CONSTRUIR SOBRE ESSES MODELOS