



ANTHROPIC · AULA 2

Os Modelos do Claude

Fable · Opus · Sonnet · Haiku. Diferenças, capacidades e aplicabilidade de cada modelo — e como escolher o certo para cada tarefa.

 Fable 5

 Opus 4.8

 Sonnet 5

 Haiku 4.5



A família *Claude*

Modelos projetados para diferentes necessidades de desempenho e custo. Um mesmo cérebro, calibrado em pontos diferentes do espectro.

FRONTEIRA

Fable 5

máxima capacidade

O mais poderoso — para os problemas mais difíceis e trabalho agêntico de longo horizonte.

FLAGSHIP

Opus 4.8

alto desempenho

Coding agêntico e tarefas complexas de alto valor, com grande autonomia.

EQUILÍBRIO

Sonnet 5

o mais versátil

Equilíbrio ideal entre inteligência e velocidade para o uso diário.

VELOCIDADE

Haiku 4.5

rápido & econômico

O mais rápido e barato — perfeito para tarefas simples em tempo real.

← mais capaz · mais rápido e acessível →

Para que serve *cada um*

Clique nas abas para ver capacidades e casos de uso ideais.

 Fable 5

 Opus 4.8

 Sonnet 5

 Haiku 4.5

Máxima inteligência

O modelo de fronteira: raciocínio profundo, execução autônoma de longo horizonte e os problemas mais difíceis que os outros modelos não resolvem sozinhos.

- ✓ Pesquisa e problemas em aberto
- ✓ Agentes autônomos longos (horas)
- ✓ Migrações de código de larga escala
- ✓ Delegação a sub-agentes em paralelo

Coding agêntico de ponta

Flagship altamente autônomo — estado da arte em trabalho de conhecimento, memória e execução multi-passo de alto valor.

- ✓ Desenvolvimento de software avançado
- ✓ Análise jurídica e de compliance
- ✓ Estratégia empresarial complexa
- ✓ Criação de conteúdo especializado

O equilíbrio perfeito

Qualidade quase-Opus em coding e tarefas agênticas, com velocidade e custo muito menores. O cavalo de batalha da produção.

- ✓ Assistentes e chatbots empresariais
- ✓ Geração e revisão de código em produção
- ✓ Automação de fluxos de trabalho
- ✓ Análise e sumarização de documentos

Velocidade máxima

- ✓ Classificação e moderação de conteúdo
- ✓ Extração de dados estruturados

Comparativo de *características*

DIMENSÃO	 FABLE 5	 OPUS 4.8	 SONNET 5	 HAIKU 4.5
Inteligência	★★★★★	★★★★★	★★★★★	★★★★★
Velocidade	★★★☆☆	★★★☆☆	★★★★★	★★★★★
Contexto	1M tokens	1M tokens	1M tokens	200K tokens
Preço (in / out por 1M)	\$10 / \$50	\$5 / \$25	\$3 / \$15	\$1 / \$5
Raciocínio complexo	Excepcional	Excepcional	Muito bom	Básico
Ideal para	Fronteira / autonomia	Alto valor	Maioria dos casos	Alto volume

💡 Todos os modelos atuais suportam raciocínio adaptativo e 1M de contexto (exceto Haiku, 200K)

Raciocínio *adaptativo*

Os modelos alocam tokens de "pensamento" de forma dinâmica. Você não define um orçamento fixo — o modelo decide quanto refletir.



Pergunta simples

"Qual a capital da França?" → resposta **instantânea**, sem gastar raciocínio.



Problema complexo

"Prove este teorema" → o modelo ativa **milhares de tokens** de reflexão antes de responder.



Parâmetro effort

low · medium · high · xhigh · max ajustam profundidade vs. custo.



Na prática: **effort alto** (high/xhigh) para coding e tarefas agênticas complexas; **effort baixo** para respostas rápidas e sensíveis a latência. O modelo interliga o raciocínio entre chamadas de ferramentas automaticamente.

Como escolher o *modelo certo*

Expanda cada cenário.

● Use Fable 5 quando...



O problema está no limite do que a IA consegue · a tarefa é um agente autônomo rodando por horas · você quer a maior taxa de acerto possível e o custo é secundário · precisa de delegação confiável a múltiplos sub-agentes.

● Use Opus 4.8 quando...



A precisão é crítica (medicina, direito, finanças) · a tarefa exige coding agêntico e raciocínio em vários passos · você precisa de alta autonomia e memória entre sessões · qualidade importa mais que custo.

● Use Sonnet 5 quando...



Você quer o melhor equilíbrio custo/desempenho · aplicações empresariais de médio a alto volume · análise de código e desenvolvimento ágil · a maioria dos casos de uso em produção.

● Use Haiku 4.5 quando...



Volume muito alto de requisições simples · latência é o fator mais importante · orçamento limitado · tarefas bem definidas e diretas · pipelines de dados automatizados.

Custo & contexto

Preço por 1 milhão de tokens (entrada / saída). Mais capaz = mais caro — escolha por adequação, não por reflexo.

● FABLE 5

\$10 / \$50

1M de contexto · pensamento sempre ativo. Para o topo da dificuldade.

● OPUS 4.8

\$5 / \$25

1M de contexto sem prêmio de contexto longo. Flagship autônomo.

● SONNET 5

\$3 / \$15

1M de contexto. Melhor ROI da produção.

● HAIKU 4.5

\$1 / \$5

200K de contexto. Viabiliza altíssimo volume.



Dica de custo: combine **prompt caching** (até ~90% de economia em contexto repetido) e **batching** (–50%). E lembre: um Sonnet bem usado costuma bater um Opus mal-orientado.

Teste *rápido*

Você precisa classificar 5 milhões de mensagens de suporte por sentimento, com latência mínima e orçamento apertado. Qual modelo?

A Fable 5

B Opus 4.8

C Sonnet 5

D Haiku 4.5

Resposta: D — Haiku 4.5. Classificação de sentimento é uma tarefa simples e bem definida; o que domina é **volume, latência e custo**. Fable ou Opus resolveriam, mas seriam caros e lentos demais para 5M de itens. Escolha o menor modelo que faz o trabalho bem.



RECAPITULANDO

A escolha certa para cada *desafio*

Não existe "melhor modelo" — existe o modelo adequado à tarefa. Comece pelo menor que resolve bem e suba de tier só quando precisar.

● Fronteira

● Alto valor

● Produção

● Escala

Próxima aula → **Claude API x Agents SDK**: como construir sobre esses modelos.