

Coleta de dados de catálogo web e geração de planilha

Extração de 50 registros de livros em books.toscrape.com e consolidação em arquivo Excel

DATA	FONTE	REGISTROS	ENTREGÁVEL
31 de agosto de 2026	books.toscrape.com	50 livros	livros_books_toscrape.xlsx

Este documento registra, passo a passo, o processo executado para **coletar nome, preço e disponibilidade de 50 livros** do catálogo público books.toscrape.com e consolidá-los em uma planilha Excel formatada, incluindo as decisões técnicas tomadas, os obstáculos encontrados e as verificações de qualidade aplicadas ao resultado final.

50 REGISTROS COLETADOS	3 PÁGINAS DO CATÁLOGO	£35,14 PREÇO MÉDIO	100% APROVAÇÃO NA VERIFICAÇÃO
---------------------------	--------------------------	-----------------------	----------------------------------

1. Etapas executadas

0 Contexto inicial — instalação do Playwright MCP

A sessão começou com um pedido de instalação do servidor Playwright MCP no Claude Code. Constatou-se que o comando grava configuração no ambiente local do usuário (`~/.claude.json`) e, portanto, precisa ser executado no terminal da própria máquina — a sessão em nuvem não tem efeito sobre esse arquivo.

```
# escopo global (todos os projetos)
claude mcp add --scope user playwright npx @playwright/mcp@latest

# conferir o registro
claude mcp list
```

Foram documentados os escopos disponíveis (`local` por padrão vs. `user`), o uso do separador `--` para argumentos próprios do `npx` e o download inicial do navegador (`npx playwright install chromium`).

1 Definição do escopo e verificação do ambiente

O escopo foi fixado em três campos por registro — **nome, preço e disponibilidade** — com saída em arquivo de planilha. Antes de qualquer coleta, verificou-se a viabilidade técnica do ambiente:

- Teste de alcance de rede até o domínio de origem;
- Disponibilidade das bibliotecas `beautifulsoup4` e `openpyxl` ;

- Definição do volume necessário: 20 livros por página → 3 páginas do catálogo cobrem os 50 registros.

Obstáculo encontrado. A requisição direta via `curl` a partir do ambiente em nuvem foi recusada pelo proxy de saída (`HTTP 403 – CONNECT tunnel failed`). A política de egresso do ambiente não autoriza esse domínio pelo canal de rede bruto.

Decisão: substituir o acesso direto pelo canal de recuperação de conteúdo web homologado da plataforma, que atende à mesma finalidade sem contornar a política vigente.

2 Coleta dos dados

As três primeiras páginas do catálogo foram recuperadas em paralelo, com uma instrução de extração idêntica para cada uma, garantindo formato de saída uniforme e comparável:

```
https://books.toscrape.com/catalogue/page-1.html
https://books.toscrape.com/catalogue/page-2.html
https://books.toscrape.com/catalogue/page-3.html
```

```
Formato de saída exigido por item:
TÍTULO | PREÇO | DISPONIBILIDADE
```

Foram retornados 60 registros. Os 50 primeiros, na ordem original do catálogo, compõem a amostra final — critério determinístico e reproduzível, sem seleção arbitrária. Títulos foram capturados na íntegra (atributo `title` do link), preservando subtítulos e numeração de série.

3 Modelagem e geração da planilha

A planilha foi construída com `openpyxl`. As decisões de modelagem priorizaram o uso posterior dos dados, e não apenas sua exibição:

- **Preço como número** (`float`), com formato de exibição `£#,##0.00` — permite ordenar, somar e calcular sem tratamento adicional;
- **Métricas por fórmula**, não por valor fixo: `COUNTA`, `AVERAGE`, `MIN` e `MAX` — o resumo recalcula sozinho se as linhas mudarem;
- **Rótulo de disponibilidade traduzido** para “Em estoque”, mantendo o preço na moeda original (£) como publicado na fonte;
- **Usabilidade:** painel congelado no cabeçalho, filtro automático, linhas zebradas, larguras ajustadas e nota de fonte com data de coleta.

```
# núcleo da geração
ws.cell(row=r, column=3, value=preco).number_format = '£#,##0.00'
ws.cell(row=54, column=3, value=f"AVERAGE(C3:C{last})")
ws.freeze_panes = "A3"
ws.auto_filter.ref = f"A2:D{last}"
```

Verificação de qualidade

O arquivo passou por recálculo completo das fórmulas e por uma bateria de conferências programáticas antes da entrega:

Verificação	Resultado
✓ Contagem de linhas de dados	50 — conforme solicitado
✓ Títulos duplicados	0 — 50 títulos únicos
✓ Células vazias em campos obrigatórios	Nenhuma
✓ Preços numéricos dentro de faixa plausível	Todos entre £12,84 e £57,31
✓ Domínio do campo disponibilidade	Valor único: "Em estoque"
✓ Erros de fórmula após recálculo	0 erros em 4 fórmulas

2. Resultado consolidado

Indicador	Valor
Registros coletados	50
Preço médio	£35,14
Preço mínimo — <i>In Her Wake</i>	£12,84
Preço máximo — <i>Slow States of Collapse: Poems</i>	£57,31
Itens em estoque	50 (100%)

Amostra dos dados (10 primeiros de 50)

#	Nome	Preço (£)	Disponibilidade
1	A Light in the Attic	51,77	Em estoque
2	Tipping the Velvet	53,74	Em estoque
3	Soumission	50,10	Em estoque
4	Sharp Objects	47,82	Em estoque
5	Sapiens: A Brief History of Humankind	54,23	Em estoque
6	The Requiem Red	22,65	Em estoque
7	The Dirty Little Secrets of Getting Your Dream Job	33,34	Em estoque
8	The Coming Woman: A Novel Based on the Life of the Infamous Feminist, Victoria Woodhull	17,93	Em estoque

#	Nome	Preço (£)	Disponibilidade
9	The Boys in the Boat: Nine Americans and Their Epic Quest for Gold at the 1936 Berlin Olympics	22,60	Em estoque
10	The Black Maria	52,15	Em estoque

A planilha entregue contém os 50 registros completos, além do bloco de resumo com fórmulas ativas.

3. Estrutura do arquivo entregue

Coluna	Conteúdo	Tipo / formato
A — #	Índice sequencial na ordem do catálogo	Inteiro
B — Nome	Título completo do livro, como publicado	Texto
C — Preço (£)	Preço de capa em libras esterlinas	Número, £#, ##0.00
D — Disponibilidade	Situação de estoque na listagem	Texto

Aba única “Livros”. Linha 1: título. Linha 2: cabeçalho com filtro. Linhas 3 a 52: dados. Linhas 54 a 57: bloco de resumo por fórmula. Nota de fonte ao final.

4. Limitações e próximos passos

Limitação	Detalhe e encaminhamento sugerido
Disponibilidade sem quantidade	A listagem do catálogo expõe apenas o rótulo “In stock”. A quantidade exata (ex.: “22 available”) existe somente na página individual de cada livro. Para obtê-la seria necessário visitar as 50 páginas de detalhe.
Retrato de um instante	Os preços refletem o catálogo em 31/08/2026. Uma coleta recorrente permitiria acompanhar variação ao longo do tempo.
Escopo de 50 de 1.000	O catálogo completo tem 1.000 títulos em 50 páginas. A mesma rotina escala para o total, com o cuidado de espaçar as requisições.
Entrega apenas no chat	Nenhuma pasta local estava conectada à sessão, então o arquivo foi disponibilizado para download. Conectar uma pasta permite gravação direta na máquina.

Fonte dos dados: <https://books.toscrape.com/> — páginas 1 a 3 do catálogo, coletadas em 31/08/2026. O site é um ambiente público mantido pela Scrapinghub especificamente para prática e testes de coleta de dados. Preços reproduzidos em libras esterlinas (£), exatamente como publicados.